Asignatura	Datos del alumno	Fecha
Aprendizaje Automático	Apellidos: Bernal Castillo	21/03/2022
	Nombre: Aldo Alberto	

Actividad: Árboles y *random forest* para regresión y clasificación

Librerias a utilizar

```
In [ ]: import pandas as pd
        import numpy as np
        from sklearn.model_selection import train_test_split
        from sklearn.tree import DecisionTreeRegressor , export_graphviz
        from sklearn.model_selection import GridSearchCV
        from sklearn.ensemble import RandomForestRegressor, ExtraTreesRegressor
        from sklearn.tree import plot_tree
        #Visualizacion
        import matplotlib.pyplot as plt
        import seaborn as sns
        import graphviz
        %matplotlib inline
        #metricas
        from sklearn.metrics import mean_squared_error
        from sklearn.metrics import mean_absolute_error
        from sklearn.metrics import r2_score
        from sklearn import svm
        from sklearn import metrics
        from funpymodeling.exploratory import freq_tbl , profiling_num
        from sklearn import preprocessing
        from sklearn.preprocessing import LabelEncoder
        from sklearn.preprocessing import StandardScaler
        from sklearn.metrics import classification_report
        from sklearn.tree import DecisionTreeClassifier
        from sklearn.model_selection import cross_val_score
        from sklearn.model_selection import KFold
        from sklearn.metrics import precision_score
        from sklearn.metrics import accuracy_score
```

Uso de las librerías

Sklearn fue la opción que se decidió usar, ya que en las practicas que se realizaron para cada tema de la materia, se uso la librería.

Asignatura	Datos del alumno	Fecha
Aprendizaje Automático	Apellidos: Bernal Castillo	21/03/2022
	Nombre: Aldo Alberto	

Lectura y primer tratamiento de datos

```
In [ ]: #Leer los datos de los archivos train y test
data_train = pd.read_csv("housing_train.csv")
data_test = pd.read_csv("housing_test.csv")
#se concatenan los 2 archivos para su mejor análisis.
frames = [data_train,data_test]
data = pd.concat(frames)
#sacamos el promedio de los precios de venta para llenar los Null que existan.
prom = data["SalePrice"].mean()
data["SalePrice"].fillna(prom , inplace = True)
data_c = data
```

Se decidió que los valores en blanco de la columna SalePrice debian rellenarse con el promedio de los demás valores, ya que esa variable es indispensable al momento de hacer nuestro modelo de regresión y el promedio se acerca un poco mas a la vida real de los precios valorados de inmuebles.

Primeros Análisis de datos

```
In [4]: #analisis estadisticos de variables numericas
data_numericos = profiling_num(data)
data_numericos
```

Con la librería **funpymodeling** , se pueden obtener fácilmente un análisis de los datos numéricos y categóricos (el detalle completo del análisis se encuentra en el código fuente anexo a este trabajo)

Datos numéricos

	variable	mean	std_dev	variation_coef	p_0.01	p_0.05	p_0.25	p_0.5	p_0.75	p_0.95	p_0.99
0	Id	1460.000000	842.787043	0.577251	30.18	146.90	730.5	1460.00000	2189.50000	2773.10	2889.82
1	MSSubClass	57.137718	42.517628	0.744125	20.00	20.00	20.0	50.00000	70.00000	160.00	190.00
2	LotFrontage	69.305795	23.344905	0.336839	21.00	32.00	59.0	68.00000	80.00000	107.00	135.68
3	LotArea	10168.114080	7886.996359	0.775660	1680.00	3182.00	7478.0	9453.00000	11570.00000	17142.90	33038.64
4	OverallQual	6.089072	1.409947	0.231554	3.00	4.00	5.0	6.00000	7.00000	8.00	10.00
5	OverallCond	5.564577	1.113131	0.200039	3.00	4.00	5.0	5.00000	6.00000	8.00	9.00
6	YearBuilt	1971.312778	30.291442	0.015366	1900.00	1915.00	1953.5	1973.00000	2001.00000	2007.00	2008.00
7	YearRemodAdd	1984.264474	20.894344	0.010530	1950.00	1950.00	1965.0	1993.00000	2004.00000	2007.00	2009.00
8	MasVnrArea	102.201312	179.334253	1.754716	0.00	0.00	0.0	0.00000	164.00000	466.50	771.05
9	BsmtFinSF1	441.423235	455.610826	1.032141	0.00	0.00	0.0	368.50000	733.00000	1274.00	1635.32
10	BsmtFinSF2	49.582248	169.205611	3.412625	0.00	0.00	0.0	0.00000	0.00000	435.00	874.66

Asignatura	Datos del alumno	Fecha
Aprendizaje Automático	Apellidos: Bernal Castillo	21/03/2022
	Nombre: Aldo Alberto	

Datos Categóricos

```
In [5]: #Analisis estadisticos de datos categoricos
        data_categoricos= freq_tbl(data)
```

```
  MSZoning  frequency  percentage  cumulative_perc
0       RL       2265    0.775951         0.777015
1       RM        460    0.157588         0.934820
2       FV        139    0.047619         0.982504
3       RH         26    0.008907         0.991424
4   C (all)        25    0.008565         1.000000

------------------------------------------------------------

  Street  frequency  percentage  cumulative_perc
0   Pave       2907    0.995889         0.995889
1   Grvl         12    0.004111         1.000000

------------------------------------------------------------

  Alley  frequency  percentage  cumulative_perc
0  Grvl        120    0.041110         0.606061
1  Pave         78    0.026721         1.000000

------------------------------------------------------------

  LotShape  frequency  percentage  cumulative_perc
0      Reg       1859    0.636862         0.636862
```

Matriz de Correlaciones

Una matriz de correlación es una tabla que indica los coeficientes de conexión entre los factores. Cada celda de la tabla muestra la conexión entre los dos factores (la matriz completa se encuentra en el código fuente de este trabajo). **Mas adelante en el trabajo se explica mas a detalle esta relación.**

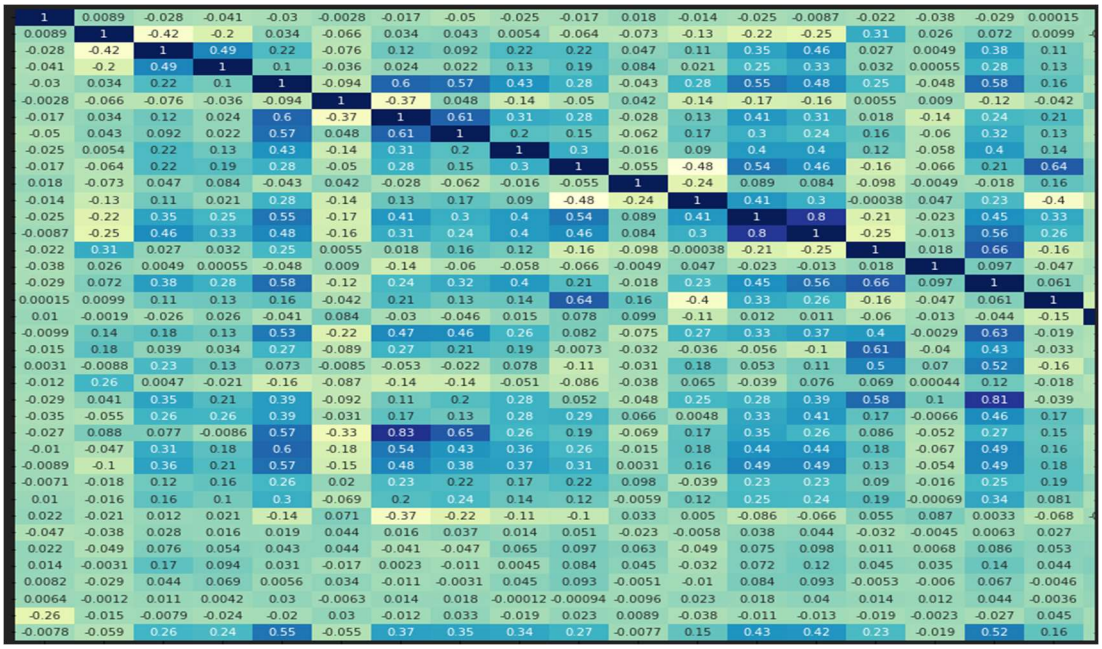

Asignatura	Datos del alumno	Fecha
Aprendizaje Automático	Apellidos: Bernal Castillo	21/03/2022
	Nombre: Aldo Alberto	

Encoder

En el proceso de procesamiento de datos, a veces necesitamos digitalizar números discretos o texto, Cuando se usa Python para el procesamiento de datos, es muy fácil usar el codificador para convertir variables ficticias (datos virtuales). El codificador puede convertir el texto en el conjunto de datos en un valor de 0 o 1. LabelEncoder y OneHotEncoder son dos funciones en el paquete scikit-learn, que pueden implementar el proceso de conversión anterior.

Se uso el encoder para así no borrar ningún dato de la base de datos, cuando aparecen datos categóricos en el conjunto de datos que queremos analizar, los datos en este momento no son ideales, **porque no podemos tratarlos matemáticamente.** Así de esta forma , no se borra ningún dato de la base de datos y se puede procesar, por que, aunque sean NaN o estén blanco, son datos a procesar que dan una mayor eficacia a nuestro modelo de **árbol y random forest.**

```
In [ ]: #Al aplicar el Encoder , llenamos los datos faltantes, caracteres extraños o NaN que existan en los datos
        le = preprocessing.LabelEncoder()
        data = data.apply(le.fit_transform)
        #data = data.apply(le.inverse_transform)
        #Separamos los datos de test y train.
        train,test = train_test_split(data,test_size = 0.2)
```

Una vez que se entrenan nuestros datos , separamos nuestras variables dependientes e independientes.

```
In [ ]: #variables dependientes e independientes
        train_x = train[[ 'Id', 'MSSubClass', 'MSZoning', 'LotFrontage', 'LotArea', 'Street',
               'Alley', 'LotShape', 'LandContour', 'Utilities', 'LotConfig',
               'LandSlope', 'Neighborhood', 'Condition1', 'Condition2',
               'BldgType', 'HouseStyle', 'OverallQual', 'OverallCond',
               'YearBuilt', 'YearRemodAdd', 'RoofStyle', 'RoofMatl',
               'Exterior1st', 'Exterior2nd', 'MasVnrType', 'MasVnrArea',
```

```
test_x = test[['Id', 'MSSubClass', 'MSZoning', 'LotFrontage', 'LotArea', 'Street',
       'Alley', 'LotShape', 'LandContour', 'Utilities', 'LotConfig',
       'LandSlope', 'Neighborhood', 'Condition1', 'Condition2',
       'BldgType', 'HouseStyle', 'OverallQual', 'OverallCond',
       'YearBuilt', 'YearRemodAdd', 'RoofStyle', 'RoofMatl',
       'Exterior1st', 'Exterior2nd', 'MasVnrType', 'MasVnrArea',
       'ExterQual', 'ExterCond', 'Foundation', 'BsmtQual', 'BsmtCond',
       'BsmtExposure', 'BsmtFinType1', 'BsmtFinSF1', 'BsmtFinType2',
```

Árbol de decisiones

Es un algoritmo de clasificación y regresión para su uso en el modelado predictivo de atributos discretos y continuos. Se crea primero el modelo y se entrena.

```
In [ ]: #Aplicamos Regresion con Arboles de desicion y entrenamos el modelo
        modelo = DecisionTreeRegressor()
        modelo.fit (train_x,train_y)
        prediccion_arb = modelo.predict(test_x)
        #Evaluacion del modelo
        print("SVM" , metrics.accuracy_score(prediccion_arb,test_y))
        print("MAE" , mean_absolute_error(test_y, prediccion_arb))
        print("MSE" , mean_squared_error(test_y , prediccion_arb))
        print("R2" , r2_score(test_y,prediccion_arb))
```

Se obtienen las primeras predicciones y primeros análisis del modelo construido:

Error cuadrático medio, mean square error (MSE). - se define como la media de la diferencia entre el valor real y el valor predicho o estimado al cuadrado

Error absoluto medio, mean absolute error (MAE). - se define como la diferencia en valor absoluto entre el valor real y el valor predicho.

Raíz del error cuadrático medio, root mean square Error (RMSE). - se define como la raíz cuadrada de la media de la diferencia entre el valor real y el valor predicho o estimado al cuadrado.

R2.- el coeficiente de determinación, determina la capacidad de un modelo para predecir futuros resultados

```
SVM 0.5256849315068494
MAE 26.892123287671232
MSE 3081.707191780822
R2 0.7943841046703279
```

Como observamos en el análisis, nuestro modelo de **Árbol de Decisión** tiene un coeficiente de predicción de 0.794384, lo cual se puede considerar alto.

Podado de árbol y estructura final

La estrategia para generar árboles más pequeños (poda) y con una menor varianza suele ser generar un árbol muy grande y después podarlo para obtener un sub-árbol. Así solo se enfoca en las variables importantes del modelo.

```
In [11]: #valores de ccp_alpha evaluados
         param_grid = {"ccp_alpha" :np.linspace(0,50,20)}
         #busqueda por validacion cruzada
         grid = GridSearchCV(
                         #el arbol se crece al maximo posible para luego aplicar el pruning
                         estimator = DecisionTreeRegressor(
                                                 max_depth = None,
                                                 min_samples_split=20,
                                                 min_samples_leaf=1,
                                                 random_state=123
                                                 ),
                         param_grid = param_grid,
                         cv = 10,
                         refit = True,
                         return_train_score = True
                         )

         grid.fit (train_x , train_y)
         modelo_final = grid.best_estimator_
         #print(f"Profundidad del arbol : {modelo_final.get_depth()}")
         #print(f"Numero de nodos terminales :  {modelo_final.get_n_leaves()}" )
         #estrucuta final
         modelo_final = grid.best_estimator_
         print(f"Profundidad del arbol : {modelo_final.get_depth()}")
         print(f"Numero de nodos terminales :  {modelo_final.get_n_leaves()}" )
```

Asignatura	Datos del alumno	Fecha
Aprendizaje Automático	Apellidos: Bernal Castillo	21/03/2022
	Nombre: Aldo Alberto	

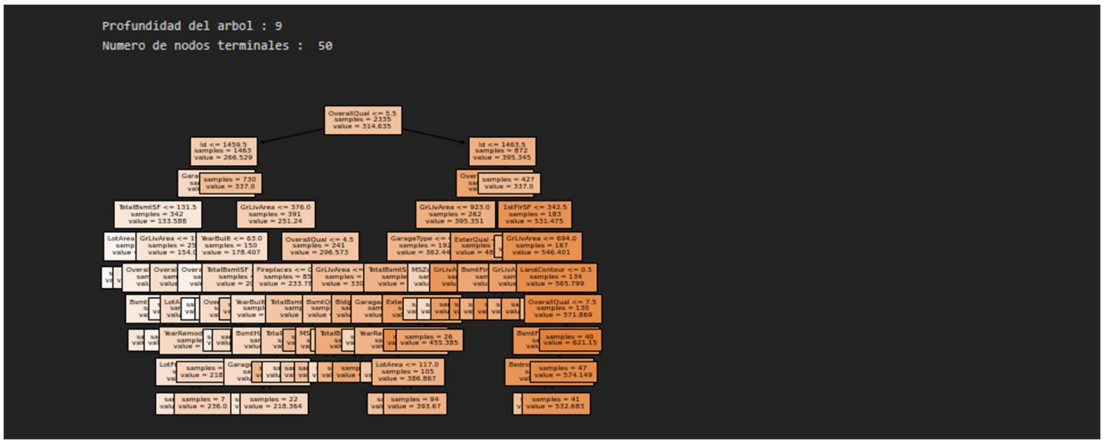

Se vuelven a analizar las métricas del modelo, comparando con el modelo de **Árbol de Decisión sin podar.**

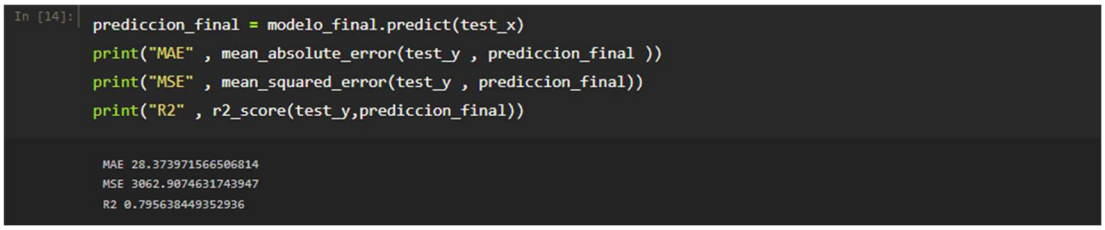

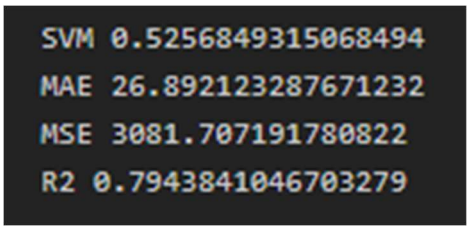

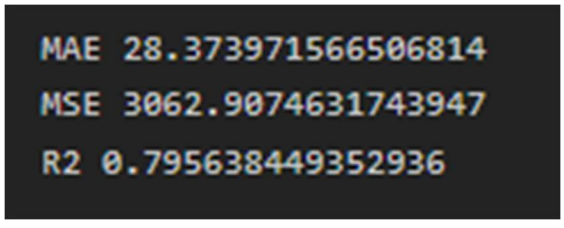

Conclusión:

Como se puede observar el modelo de **Árbol de Decisión con poda tiene mejor predicción que el Árbol de Decisión sin podar**

Asignatura	Datos del alumno	Fecha
Aprendizaje Automático	Apellidos: Bernal Castillo	21/03/2022
	Nombre: Aldo Alberto	

Random Forest

Es un método versátil de aprendizaje automático capaz de realizar tanto tareas de regresión como de clasificación. También lleva a cabo métodos de reducción dimensional, trata valores perdidos, valores atípicos y otros pasos esenciales de exploración de datos. Es un tipo de método de aprendizaje por conjuntos, donde un grupo de modelos débiles se combinan para formar un modelo poderoso. Se puede decir que son varios árboles de decisión en un solo modelo.

Creación del modelo y entrenamiento

```
In [15]: #Creacion del modelo Random Forest y entrenamiento
         rf_model = RandomForestRegressor(
                                          n_estimators=25,
                                          criterion = "mse",
                                          max_depth = None,
                                          max_features = "auto",
                                          oob_score = False,
                                          n_jobs = -1 ,
                                          random_state = 123
         )
         rf_model.fit(train_x,train_y)
```

Se obtienen las primeras predicciones y primeros análisis del modelo construido, el R2 indica que **Random Forest** tiene una mayor predicción que los **Arboles de Decisión** para este ejemplo.

```
In [16]: #Evaluacion del modelo Random Forest

         prediccion_rd = rf_model.predict(test_x)
         #Evaluacion del modelo
         #print("SVM" , metrics.accuracy_score(prediccion_rd,test_y))
         print("MAE" , mean_absolute_error(test_y, prediccion_rd))
         print("MSE" , mean_squared_error(test_y , prediccion_rd))
         print("R2" , r2_score(test_y,prediccion_rd))
```

Asignatura	Datos del alumno	Fecha
Aprendizaje Automático	Apellidos: Bernal Castillo	21/03/2022
	Nombre: Aldo Alberto	

```
MAE 20.58027397260274
MSE 1891.859287671233
R2 0.8737724523894539
```

```
MAE 28.373971566506814
MSE 3062.9074631743947
R2 0.795638449352936
```

Lista de importancia de cada variable para la regresión de Random Forest y Arboles de Decisión.

Como se dijo anteriormente, la matriz de correlación y la lista de importancia tiene gran significado en el análisis de los datos ya que muestra las variables mas importantes y su relación con el entorno. En la siguiente grafica podemos ver un listado de mayor a menor las variables que se usan en el algoritmo para sus predicciones. (la matriz y el listado completos se encuentra en el código fuente de este trabajo).

	Caracteristicas	Importancia
0	Id	0.311383
17	OverallQual	0.096795
46	GrLivArea	0.095448
27	ExterQual	0.058689
19	YearBuilt	0.035174
...	...	...
71	PoolArea	0.000355
45	LowQualFinSF	0.000351
74	MiscFeature	0.000304
5	Street	0.000262
9	Utilities	0.000035

80 rows × 2 columns

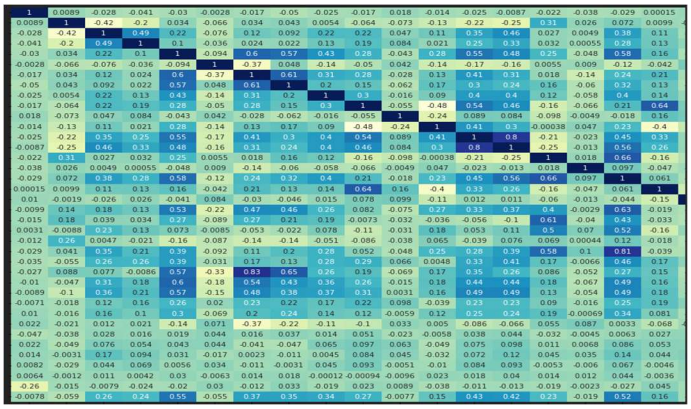

Comenta las ventajas y desventajas de cada modelo. De acuerdo con los resultados, ¿son realmente útiles los modelos creados para el conjunto de datos propuesto?

El modelo de **Arboles de Decisión** resulto tener un poco menos de confiabilidad que **Random Forest**, esto debido a la gran cantidad de datos que el algoritmo tiene que usar. Al momento de usar **Random Forest** y clasificarlos en diferentes arboles (y no en uno solo como lo hace el algoritmo de **Arboles de Decisión**), se puede obtener más fiabilidad.

Algoritmos de Clasificación

Los algoritmos de clasificación nos permiten, como su nombre lo dice, ordenar información de una manera especial basándonos en un criterio de ordenamiento**.** Se usan cuando el resultado deseado es una etiqueta discreta, en otras palabras, son útiles cuando la respuesta al problema cae dentro de un conjunto finito de resultados posibles.

Discretizando los datos

Se empieza a cortar a hacer los grupos con respecto a los precios de las casas

```
#Se empeiza a cortar a hacer los grupos con respecto a los precios de las casas

data_c["Clasificacion"] = pd.cut(data_c["SalePrice"], bins=[34900, 100000, 500000, 755000],labels=["Grupo1"
```

Comprobamos que realmente se hizo la clasificación:

```
data_c["Clasificacion"].value_counts()

Grupo2    2787
Grupo1     122
Grupo3       9
Name: Clasificacion, dtype: int64
```

Se divide el conjunto de datos en (X) variables de características y (Y) variable objeto

```
In [ ]: #dividimos el conjunto de datos en (X) variables de caracteristicas y (Y) variable objeto
        data_c = data_c.apply(le.fit_transform)
        X = data_c[["SalePrice" , "Clasificacion"]]
        Y =data_c["Clasificacion"]
```

Modelo de clasificación

Se empieza por hacer el modelo de clasificación por árboles, se crea el modelo y se entrena, además obtenemos nuestros primeros análisis del modelo

```
In [ ]: x_train,x_test , y_train , y_test = train_test_split(X ,Y ,train_size = 0.5 , random_state = 0)
        #entrenar el modelo
        modelo_arb_c = DecisionTreeClassifier(random_state = 1)
        modelo_arb_c.fit(x_train,y_train)
        predicciones = modelo_arb_c.predict(X = x_test,)
        print(classification_report(y_test , predicciones))
```

```
              precision    recall  f1-score   support

           0       0.98      1.00      0.99        63
           1       1.00      1.00      1.00      1395
           2       1.00      1.00      1.00         2

    accuracy                           1.00      1460
   macro avg       0.99      1.00      1.00      1460
weighted avg       1.00      1.00      1.00      1460
```

Como se puede observar en el análisis, tenemos un Accuracy y precisión muy altos , del 98% y 99% respectivamente, lo que indica que nuestro modelo puede predecir el grupo sin ningún problema.

Cross-Validation K-Fold

```
#Cross-Validation
kf = KFold(n_splits = 5)#numero de iteraciones
puntuaciones = cross_val_score(modelo_arb_c,x_train , y_train , cv = kf , scoring = "accuracy")
print ("Metricas Cross_validation" , puntuaciones)
```

```
Metricas Cross_validation [0.99657534 1.         0.99657534 1.         1.        ]
```

Accuracy

```
#Accuracy
accuracy = accuracy_score( y_true = y_test , y_pred = predicciones, normalize = True)
print(f"el accuracy de test es :  {100*accuracy} %")
```

```
el accuracy de test es :  99.93150684931507 %
```

Curvas ROC/AUC

cuando se trata de un problema de clasificación, podemos contar con una curva AUC-ROC. Esta es una de las métricas de evaluación más importante para verificar el rendimiento de cualquier modelo de clasificación. Esta métrica se utiliza
para determinar el balance entre la detección de verdaderos positivos y evitar los falsos positivos. Para ello, se muestra la proporción de detección de los verdaderos positivos en el eje vertical y la proporción de los falsos positivos en el eje horizontal, para un umbral o punto de corte determinado

Asignatura	Datos del alumno	Fecha
Aprendizaje Automático	Apellidos: Bernal Castillo	21/03/2022
	Nombre: Aldo Alberto	

Conclusiones

Para los algoritmos de regresión usados en este ejercicio , Arboles de Decisión y Random Forest, se obtuvo un rendimiento y una predicción alta, considerando la cantidad de datos usados. Muchos de estos datos se podrían consideran innecesarios (espacios en blanco, caracteres raros o NaN) pero para el algoritmo son necesarios por que tiene una **mas fiabilidad** al momento de determinar el precio de venta de la casa. Para ambos algoritmos se obtuvo una predicción muy alta , para el modelo usado.

En el caso de los algoritmos de regresión, se obtuvo resultados y análisis de predicción muy altos del casi .99%, lo cual indica que el modelo creado es perfecto para el uso de predicciones en categorías para la base de datos.

Bibliografías:

*Análisis de Datos categóricos con Python. (s. f.). Python. Recuperado 21 de marzo de 2022, de https://relopezbriega.github.io/blog/2016/02/29/analisis-de-datos-categoricos-con-python/

*Método de preprocesamiento de datos para digitalizar datos de categoría-LabelEncoder VS OneHotEncoder - programador clic. (s. f.). Python. Recuperado 21 de marzo de 2022, de https://programmerclick.com/article/77681608357/

**funpymodeling*. (2020, 16 septiembre). PyPI. https://pypi.org/project/funpymodeling/