Inducción a las herramientas del espacio UNAM – Huawei para investigación en Inteligencia Artificial



Enero de 2023. Ver 2.0
Elaborado por Fabián Romo Zamudio

DGTIC UNAM
DIRECCIÓN GENERAL DE CÓMPUTO Y DE TECNOLOGÍAS DE INFORMACIÓN Y COMUNICACIÓN

HUAWEI

Agenda por sesiones.
Primera parte

1	A) Infraestructura del espacio de innovación UNAM – Huawei B) Entorno de desarrollo MindStudio	2 horas
2	Plataforma Mindspore	2 horas
3	Acceso a la infraestructura	2 horas

Confidencial UNAM – Huawei
Elaborado por Fabián Romo Zamudio

DGTIC UNAM
DIRECCIÓN GENERAL DE CÓMPUTO Y DE TECNOLOGÍAS DE INFORMACIÓN Y COMUNICACIÓN

HUAWEI

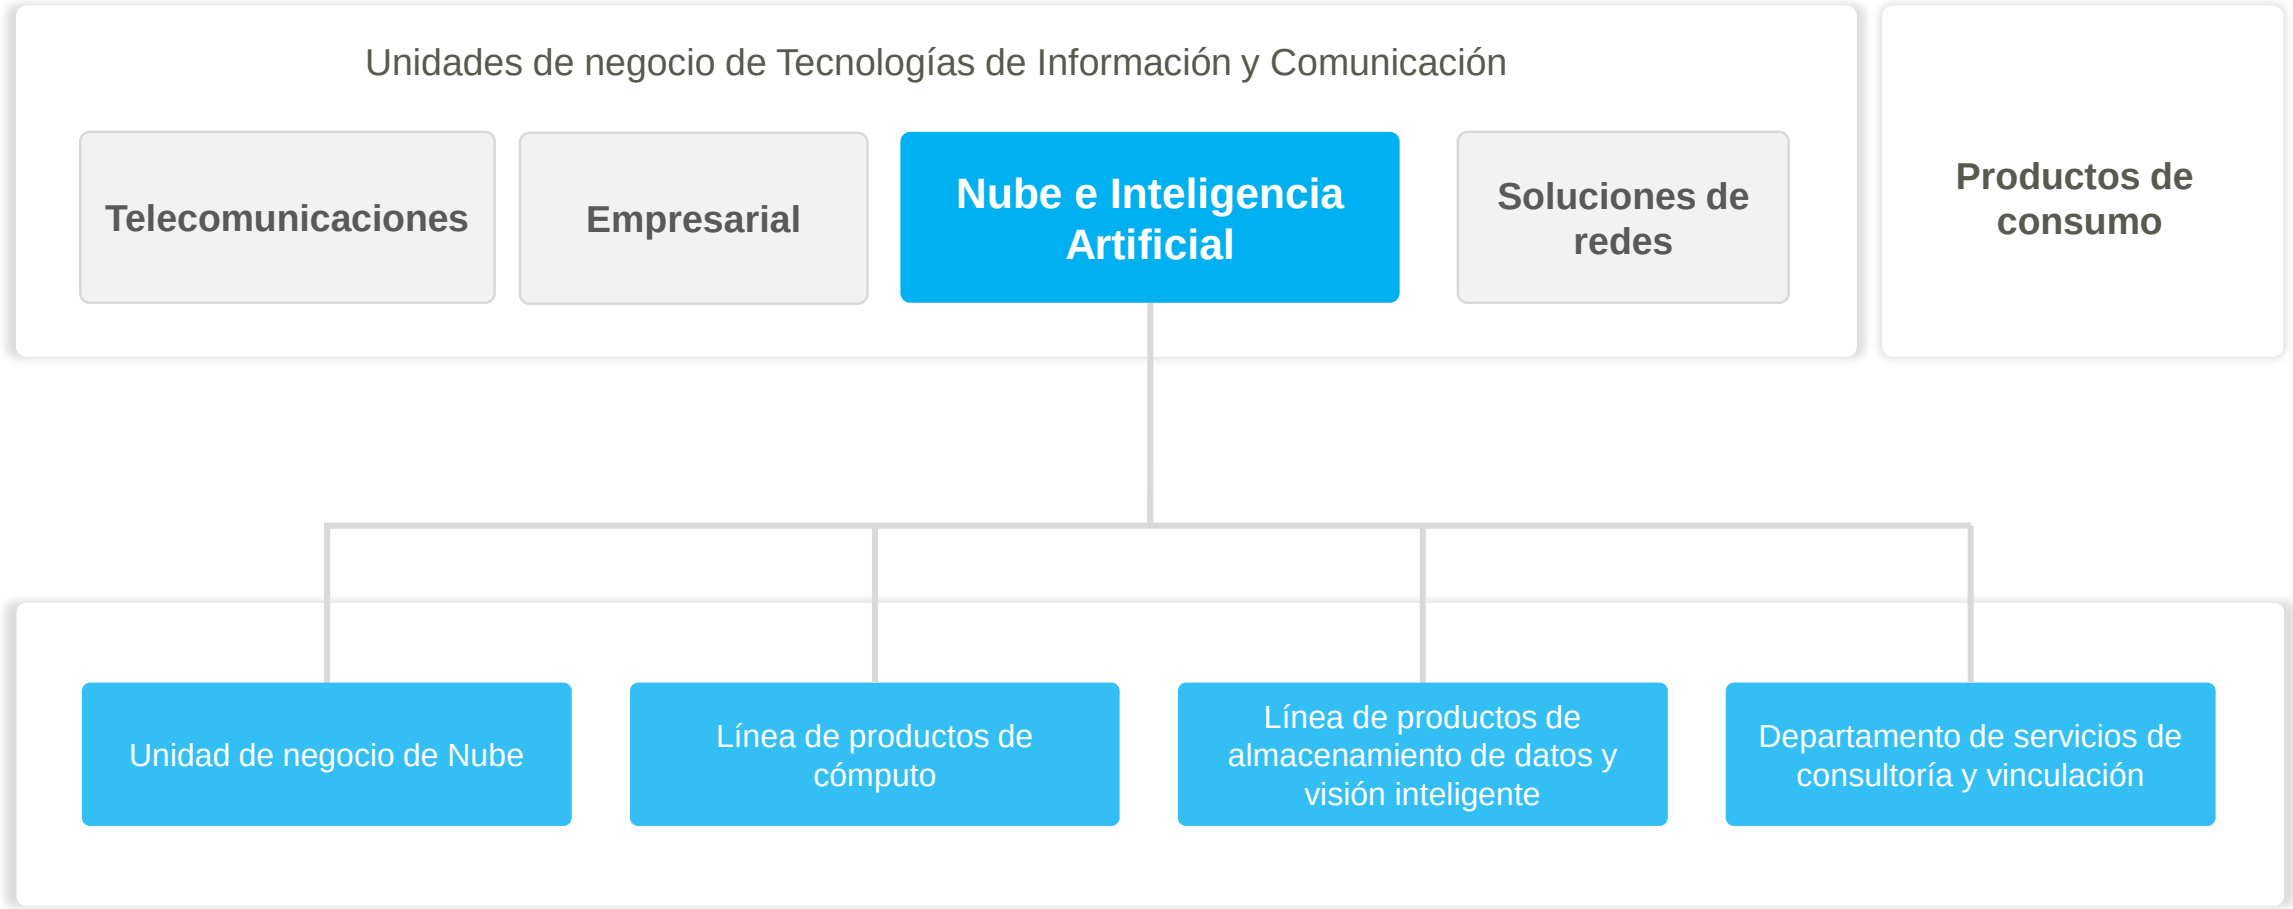
Infraestructura del espacio de innovación UNAM - Huawei



DGTIC UNAM
DIRECCIÓN GENERAL DE CÓMPUTO Y DE TECNOLOGÍAS DE INFORMACIÓN Y COMUNICACIÓN

HUAWEI

Huawei estableció sus grupos de negocios con soluciones de Nube e Inteligencia Artificial en 2020.



Confidencial UNAM – Huawei
Elaborado por Fabián Romo Zamudio

Visión general del ecosistema abierto

Ecosistema abierto

Hardware abierto | Software de fuente libre | Socios colaboradores

Nube Huawei

Servicios básicos | Servicios empresariales | Servicios de aplicaciones



Cómputo

Cómputo propósito general | Cómputo IA | Cómputo de frontera

Almacenamiento de datos y visión de máquina

Almacenamiento| Visión de máquina | Colaboración inteligente

Procesadores Kunpeng / Intel

Procesadores Ascend/GPU

Familias de procesadores Kunpeng y Ascend



Cómputo

Kunpeng | procesador de uso general

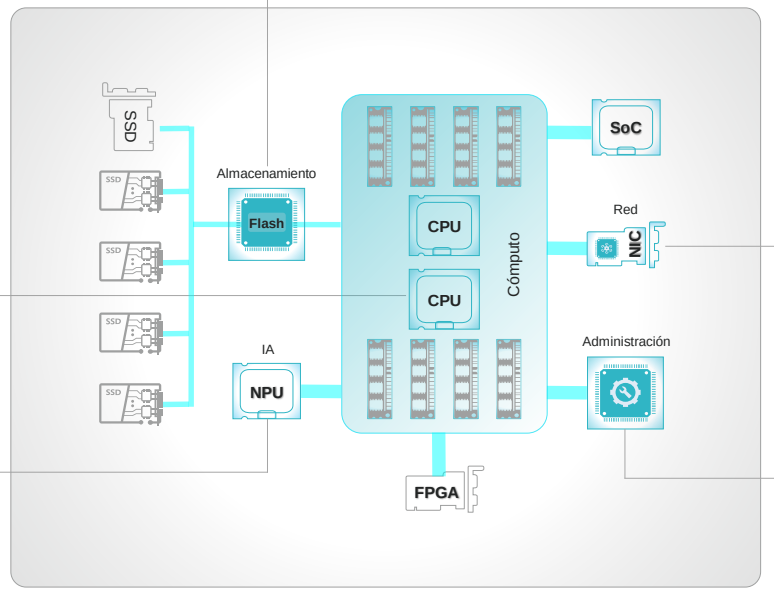
- Alto rendimiento: 64 núcleos, 930 puntos en el protocolo de rendimiento SPECint para un solo procesador, 25% superior a los tradicionales
- Elevada respuesta: 8 canales de memoria, 3,200 MHz, PCIe 4.0, 46% mayor ancho de banda que otros procesadores
- Alta integración: Controlador 4 en 1 (CPU, southbridge, RoCE, y SAS)



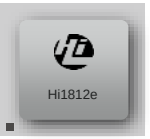
IA

Ascend | Procesador de Inteligencia Artificial

- Alto rendimiento: Ascend 910, 256 TFLOPS FP16, duplica a su equivalente en la industria
- Eficiencia energética: Ascend 310, 16 TOPS INT8 a 8 W (vs . 10 W de su contraparte en la industria)



Almacenamiento



Chip controlador de SSD

- Concurrencia de 16 canales 15% superior en lectura y escritura
- Algoritmo de operación optimizado. Vida útil superior en 20%

Red



Chip inteligente NIC

- Múltiples hosts, múltiples controladores AA para accesibilidad al dato
- Protocolos OVS, VxLAN, y RoCE para redes basadas en nube y baja latencia

Administración



Chip de gestión inteligente

- Gestión inteligente 93% más precisa para localización de fallas (vs. 60% promedio de la industria)
- Ajuste dinámico del consumo energético, 15% más eficiente

DGTIC UNAM
DIRECCIÓN GENERAL DE CÓMPUTO Y DE TECNOLOGÍAS DE INFORMACIÓN Y COMUNICACIÓN

HUAWEI

Capacidad de cómputo diversa para aplicaciones generales y específicas de Inteligencia Artificial

Plataforma de cómputo Kunpeng

Tarjetas madre Kunpeng |
Servidores TaiShan | Sistema Operativo openEuler

openEuler





Plataforma de cómputo Ascend

Atlas











Plataforma de cómputo x86

FusionServer Pro



Componentes para aceleración de procesamiento







Motores de gestión



FusionDirector

Cinco características para gestión inteligente

Confidencial UNAM – Huawei
Elaborado por Fabián Romo Zamudio

DGTIC UNAM
DIRECCIÓN GENERAL DE CÓMPUTO Y DE TECNOLOGÍAS DE INFORMACIÓN Y COMUNICACIÓN

HUAWEI

Open Euler



https://www.openeuler.org/en/

Varios dispositivos

- ARM
- X-86
- RISC –V
- SW-64
- LoongArch
- NPU
- DGPU
- DPU
- + 100 dispositivos + 30 tarjetas

Servidores | Cómputo en nube
Cómputo de extremo | Dispositivos incorporados

Aplicaciones

- Tecnología de información
- Tecnología de comunicación
- Tecnología de operación

- IA
- CRM
- ERP
- BSS / OSS
- NFV
- DCS
- SCADA
- PLC

Cadena de desarrollo

- OpenEuler DevKit
  - Herramienta de desarrollo multi-dispositivo
  - Compatibilidad
  - Portabilidad

- SDKs OpenAuler
  - Multiarquitectura
  - Cómputo confidencial
  - Compatiblidad de aplicaciones

DGTIC UNAM DIRECCIÓN GENERAL DE CÓMPUTO Y DE TECNOLOGÍAS DE INFORMACIÓN Y COMUNICACIÓN

HUAWEI

Plataforma + IA + ecosistema para facilitar la transformación digital



Funciones públicas y gubernamentales



Finanzas



Transportes



Energía



Manufactura



Telecomunicaciones

Plataforma + **IA** + **Ecosistema**

Confidencial UNAM – Huawei
Elaborado por Fabián Romo Zamudio

DGTIC UNAM
DIRECCIÓN GENERAL DE CÓMPUTO Y DE TECNOLOGÍAS DE INFORMACIÓN Y COMUNICACIÓN

HUAWEI

Una plataforma de cómputo de IA para facilitar la investigación y el desarollo.

SDK para la industria
IA/Manufactura...

Model Zoo

Plataforma de frontera IA Atlas

Contenedor motor/ repositorio básico de servicios

Plataforma de aprendizaje profundo Atlas

Gestión de cluster / modelo de gestion / modelo de procesamiento

Entorno de desarollo **MindSpore / TensorFlow / PyTorch/ …**

Tipo de chip **CANN**

Dispositivo



Teléfonos inteligentes



Dispositivos con chips inteligentes

Núcleos IP incluidos para mejor experiencia

Frontera



Atlas 200



Atlas 300I AI inference card



Atlas 500



Atlas 500 Pro

Mejor eficiencia energética, adaptable al tipo de cliente

Nube



Atlas 300I AI tarjeta de inferencia



Atlas 300T AI tarjeta de entrenamiento



Atlas 900 PoD



Atlas 800 AI servidor de inferencia

Solución de inferencia para el Centro de Datos



Atlas 800 AI Servidor de entrenamiento

Solución de entrenamiento para el Centro de Datos



Atlas 900 AI cluster

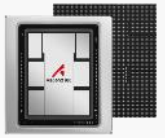
Solución de supercómputo para Inteligencia Artificial



Ascend 310

Arquitectura Da Vinci

Ascend 910



Herramienta de desarollo

MindStudio

Herramientas de Operación y Mantenimiento (O&M)

FusionDirector/SmartKits

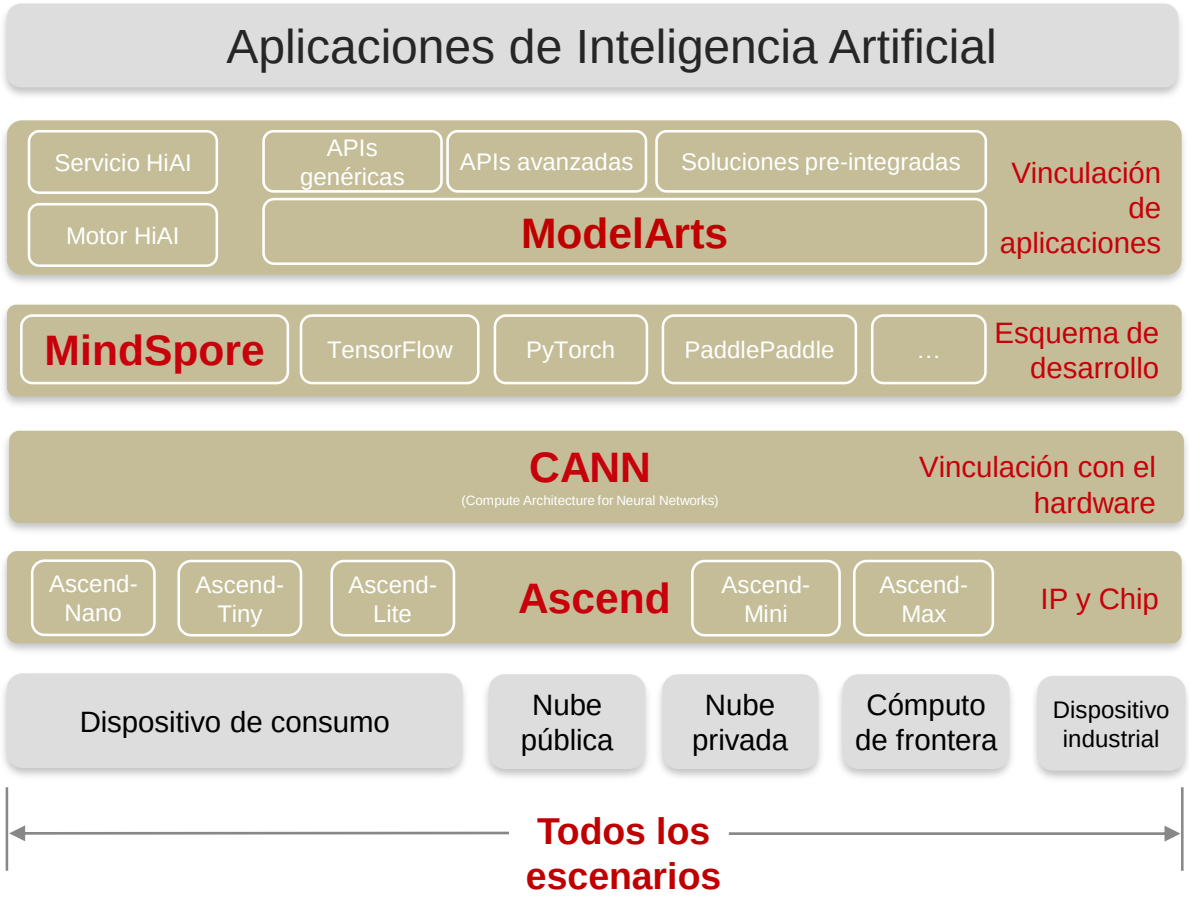
Comunidad Ascend

DGTIC UNAM DIRECCIÓN GENERAL DE CÓMPUTO Y DE TECNOLOGÍAS DE INFORMACIÓN Y COMUNICACIÓN

HUAWEI

Modelo y portafolio completo de soluciones Huawei para Inteligencia Artificial

Esquema completo



Vinculación de aplicaciones: Flujo completo de servicios (**ModelArts**), APIs jerárquicas y soluciones pre integradas.

MindSpore: Esquema de desarrollo unificado para entrenamiento e inferencia para dispositivo, equipos de frontera y nube cloud (tanto aislado como cooperativo)

CANN: Librería de operadores para los chips y kit de herramientas con operadores altamente automatizados

Ascend: Serie de chips de IA IP basada en una arquitectura unificada escalable

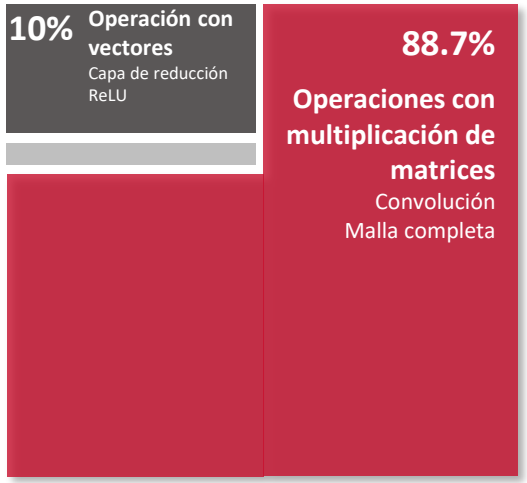
Confidencial UNAM – Huawei
Elaborado por Fabián Romo Zamudio

Arquitectura Da Vinci. La base de la potencia de cómputo para Inteligencia Artificial

Características del cómputo para IA

~90% son operaciones de multiplicación de matrices

- El cómputo de IA se basa principalmente en modelos CNN (Redes Neuronales Convolucionales)
- Cerca del 90% del modelo CNN esta basado en operaciones de multiplicación de matrices
- La **unidad de cómputo cúbica** es la más adecuada



Arquitectura Da Vinci: diseñada en específico para cómputo de Inteligencia Artificial

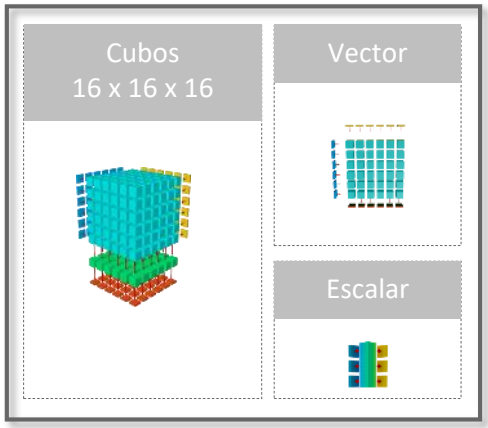
GPU

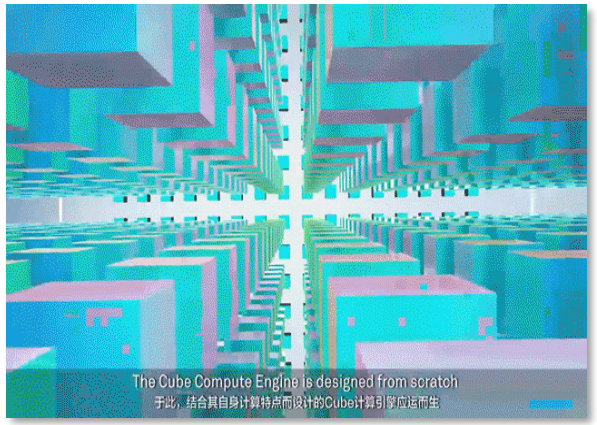
- **La GPU no está diseñada para cómputo de IA.** En consecuencia, es ineficiente para el cómputo de multiplicación de matrices

NPU

- La arquitectura Da Vinci está **específicamente diseñada para el cómputo de IA.**
- Proporciona unidades de cómputo escalar, vectorial y cúbicas para el cómputo de IA
- La arquitectura Da Vinci atiene una gran proporción de cubos, permitiendo **una alta eficiencia en el cómputo de multiplicación de matrices y una óptima relación área – eficiencia.**







2 veces relación área – eficiencia

En a misma área, la arquitectura Da Vinci proporciona el doble de capacidad computacional.

	Otras arquitecturas de chip para IA	Arquitectura Da Vinci
Área del chip (12nm)	5.x mm^2	13.x mm^2
Capacidad de Cómputo	1.7 TOPS FP16	8 TOPS FP16
Relación área - eficiencia	**~0.3**	**~0.6**

Confidencial UNAM – Huawei
Elaborado por Fabián Romo Zamudio

DGTIC UNAM
DIRECCIÓN GENERAL DE CÓMPUTO Y DE TECNOLOGÍAS DE INFORMACIÓN Y COMUNICACIÓN

HUAWEI

Los procesadores Ascend de IA están enfocados en agregar más inteligencia al cómputo



Ascend 310

SoC de IA con major relación Rendimiento / Watt

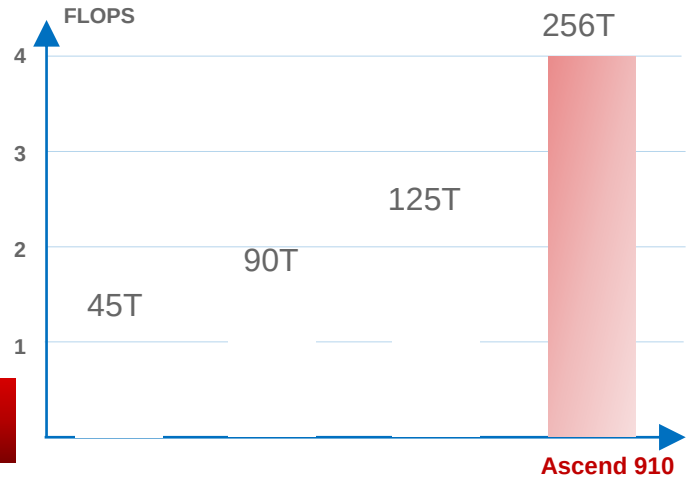
- Ascend-Mini
- Arquitectura Da Vinci
- **Semi-precisión (FP16): 11 TFLOPS**
- **Precisión entera (INT8): 22 TOPS**
- **Decodificador Full-HD de video con 20 canales : H.264/265**
- Codificador de 1 canal Full-HD: H.264/265
- **Máximo consumo: 8 W**



Ascend 910

La mayor densidad de cómputo en un solo chip

- Ascend-Max
- Arquitectura Da Vinci
- **Media precisión (FP16): 280 TFLOPS**
- **Precisión entera (INT8): 560 TOPS**
- **Decodificador Full-HD de video con 128 canales: H.264/265**
- Máximo consumo: 350 W



* Normalizado a 16-bits

Confidencial UNAM – Huawei
Elaborado por Fabián Romo Zamudio

DGTIC UNAM
DIRECCIÓN GENERAL DE CÓMPUTO Y DE TECNOLOGÍAS DE INFORMACIÓN Y COMUNICACIÓN

HUAWEI

Tarjeta para entrenamiento Atlas 300T

- Tarjeta de entrenamiento basada en el procesador de IA Ascend 910
- Opera en los servidores para incrementar la capacidad de cómputo para inteligencia artificial en los Centros de Datos
- Características:
  - Alta densidad de cómputo
  - Óptimo ancho de banda
  - Tarjeta de tamaño estándar ¾ PCIe
  - Adaptable a servidores de propósito general
  - Cumple con especificaciones de empresas de telecomunicaciones, financieras e instituciones de investigación para entrenamiento de IA



Servidor para entrenamiento Atlas 800

- Usado en escenarios de entrenamiento de IA y aprendizaje profundo
- Optimizado para servicios en nube, Internet, telecomunicaciones, gobierno, transporte, finanzas, universidades y gestión energética.
- Alta densidad de cómputo
- Tasa de consumo energético óptima
- Fácil expansión y administración
- Enfriable por aire o líquido
  - Modelo 9000: Servidor para entrenamiento de IA basado en procesadores Ascend 910 y Kunpeng 920
  - Modelo 9010: Servidor de entrenamiento de IA basado en procesadores Ascend 910 e Intel



Confidencial UNAM – Huawei
Elaborado por Fabián Romo Zamudio

Servidor para entrenamiento Atlas 900

- Servidor para integración en clúster
- Alta densidad y rendimiento
- Mayor eficiencia energética
- Gestión y operación unificadas
- Bajo costo total de propiedad (TCO)
- Aplicable para
  - Cómputo en nube
  - Virtualización
  - Big data
  - Telecomunicaciones
  - Servicios de Internet.



DGTIC UNAM
DIRECCIÓN GENERAL DE CÓMPUTO Y DE TECNOLOGÍAS DE INFORMACIÓN Y COMUNICACIÓN

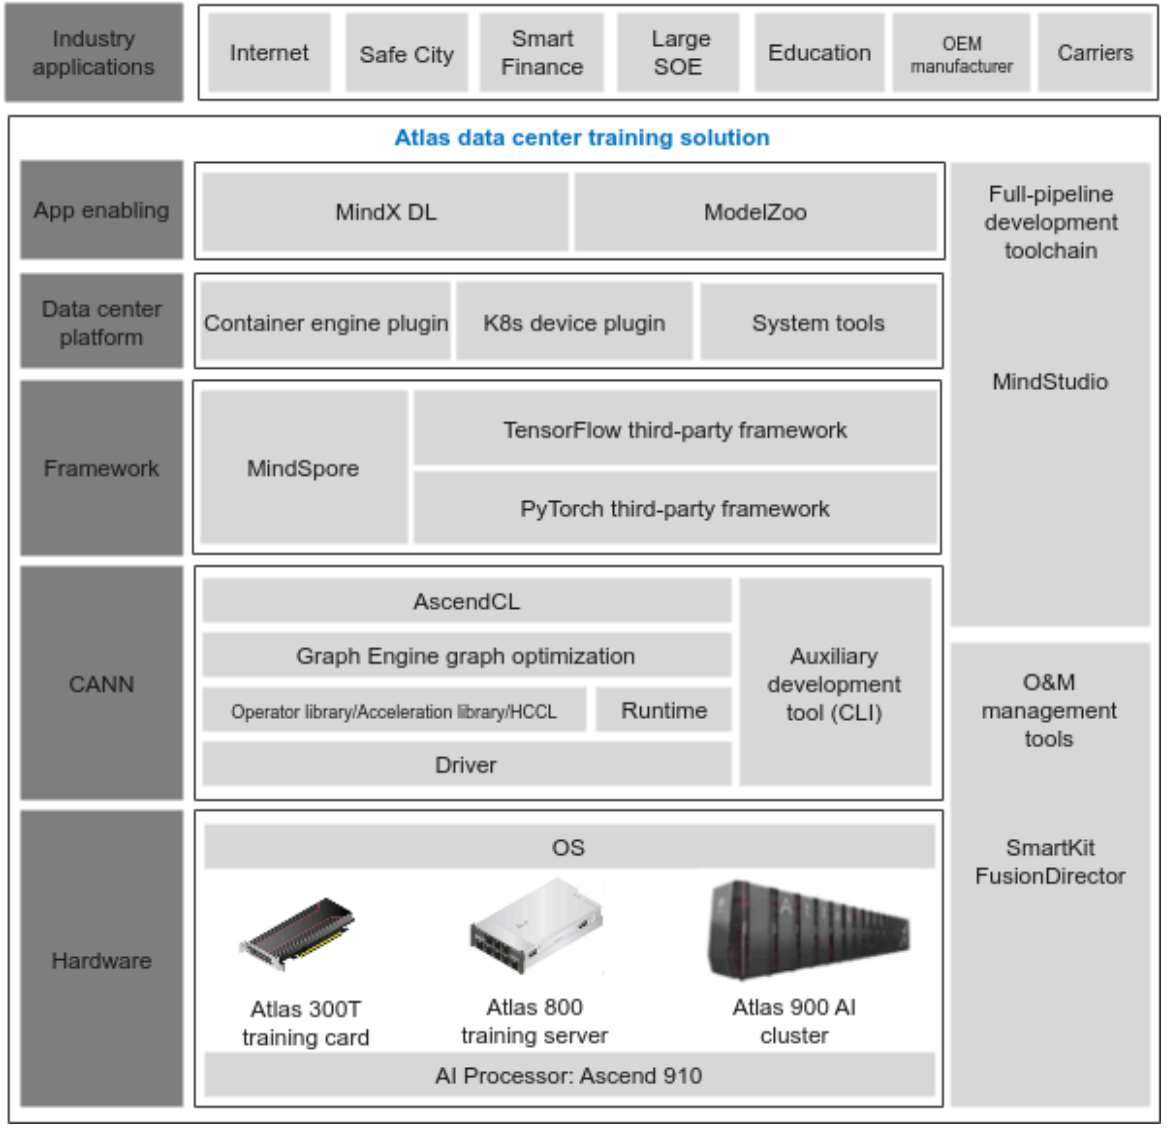
HUAWEI

Escenarios de aplicación

- Los servidores en el espacio UNAM – Huawei son los mismos que se usan en aplicaciones de centros de datos y Supercómputo.
- La solución completa cosiste en software y hardware, *end-to-end*, para el desarrollo y entrenamiento de modelos de inteligencia artificial

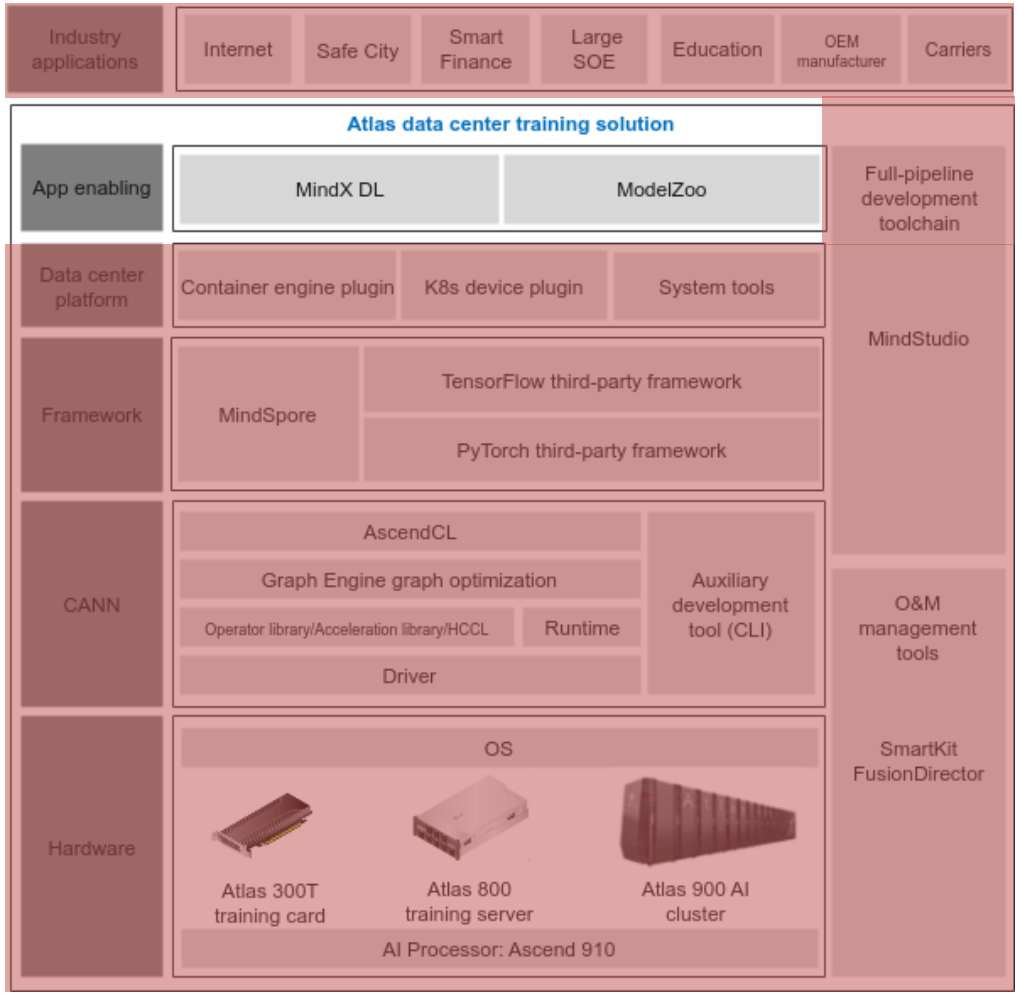
Industria	Escenario	Descripción	Tipo de solución física
Industria tradicional	Detección de calidad, OCR, sistemas de aprendizaje profundo (DLS)	Para usuarios que no tienen soluciones propias de DLS. El usuario requiere un DLS fácil de usar que integre software hardware.	Solución integral de hardware y software Atlas 800
Internet, seguridad y protección	Moderación de contenido, análisis de video e imágenes, DLS	El usuario tiene un DLS propio. El usuario requiere componentes que se adapten al DLS para entrenar rápidamente modelos de IA.	Servidor Atlas 800 que se asocie a un clúster del usuario Entorno abierto de desarrollo basado en las tarjetas Atlas 300T 9000
Supercómputo, centros de datos o nube pública	Servicios de nube para investigación científica, y entrenamiento de IA	El usuario no tiene un clúster de entrenamiento para IA. El usuario requiere clústers para entrenamiento en gran escala de IA, que soporten desarrollos de alta densidad y con ello reducir los tiempos de ejecución y entrega de resultados, acelerando la viabilidad de los modelos de redes neuronales.	Clúster basado en Atlas 900
Otros segmentos	Investigación en algoritmos	Interfaz basada en comandos para el entrenamiento de IA y la investigación en algoritmos El usuario necesita una herramienta distribuida basada en comandos (CLI) para simplificar el entrenamiento de modelos y mejorar su usabilidad..	Ecosistema abierto de hardware basado en las tarjetas Atlas 300T 9000

Arquitectura del ecosistema



Confidencial UNAM – Huawei
Elaborado por Fabián Romo Zamudio

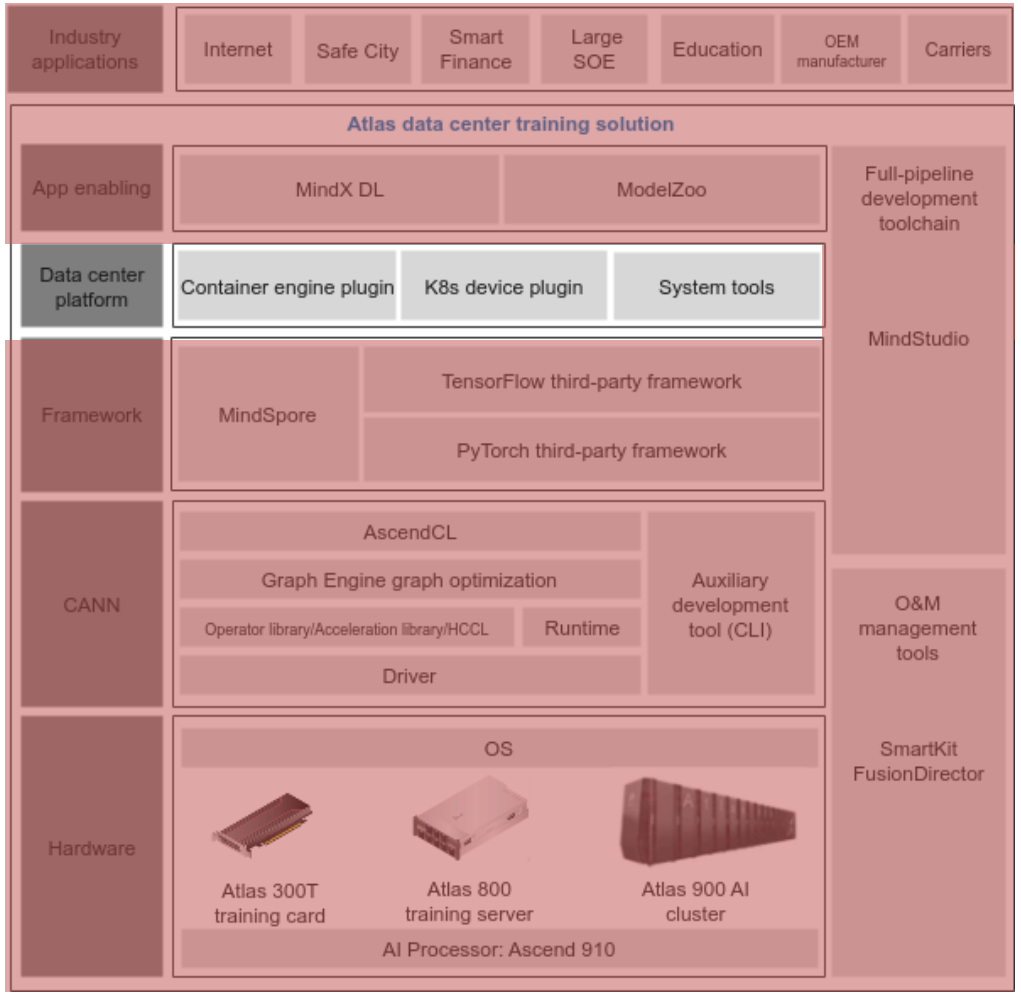
Arquitectura del ecosistema. Componentes



Capa	Componente	Descripcion
Habilitación de aplicaciones	MindX DL	MindX DL es un diseño de referencia para aprendizaje profundo que considera a los servidores Atlas 800 de entrenamiento, servidores Atlas 800 de inferencia y servidores basados en GPU. Proporciona funciones básicas tales como la gestión y monitoreo de los recursos de los procesadores de IA Ascend, la optimización en la programación de los trabajos del procesador y la generación de comunicaciones distribuidas para el entrenamiento de los modelos. Permite un desarrollo más rápido de sistemas de aprendizaje profundo. Se puede acceder a la zona de desarrolladores Ascend para obtener códigos y documentos de referencia.
	ModelZoo	ModelZoo proporciona modelos de redes neuronales comunes, apoyándose en la experiencia de frameworks como MindSpore, TensorFlow, y Caffe, lo que incluye a ResNet50 y VGG16. Después de obtener el modelo se puede realizar entrenamiento personalizado o desarrollar una nueva aplicación basada en el modelo y en los procesadores de IA Ascend. Los recursos de ModelZoo están disponibles en la comunidad de Ascend..

Confidencial UNAM – Huawei
Elaborado por Fabián Romo Zamudio

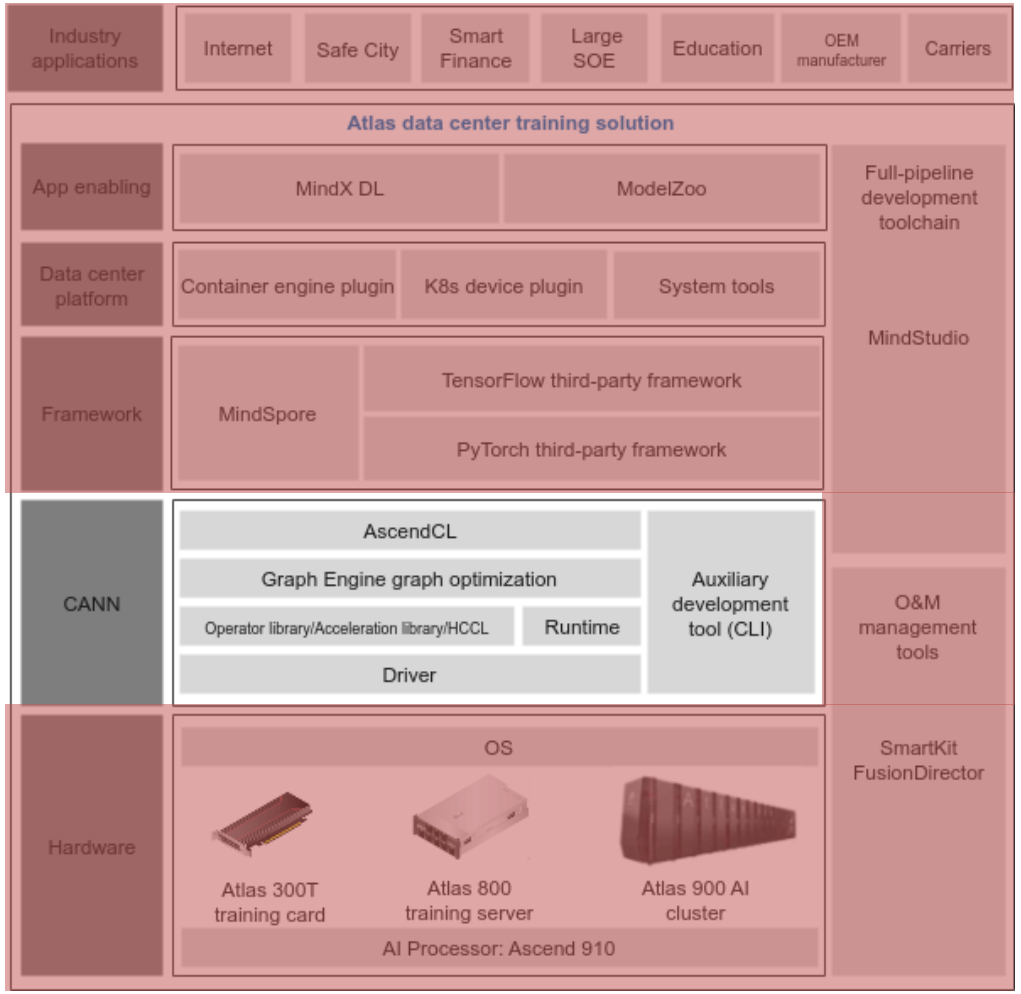
Arquitectura del ecosistema. Componentes



Capa	Componente	Descripción
Plataforma de centro de datos	Plug-in del motor de contenedores (Ascend Docker)	El contenedor Ascend es un elemento básico de la solución Atlas en el Centro de Datos, ya que permite montar dispositivos y controladores para los procesadores de IA Ascend en los contenedores de tal forma que los trabajos de IA puedan ejecutarse como Dockers en los servidores
	Plug-in de dispositivos Kubernetes	Kubernetes proporciona un mecanismo de plug-ins para dispositivos de terceros. El Procesador Ascend de IA usa el plug-in de dispositivos Kubernetes para descubrir y reportar los recursos al kubelet. Adicionalmente, el dispositivo se puede usar como un POD K8S y un contenedor para verificar periódicamente el estado operativo del dispositivo.
	Herramientas del sistemas	Las herramientas basadas en CANN son fáciles de desplegar y mantener.

Confidencial UNAM – Huawei
Elaborado por Fabián Romo Zamudio

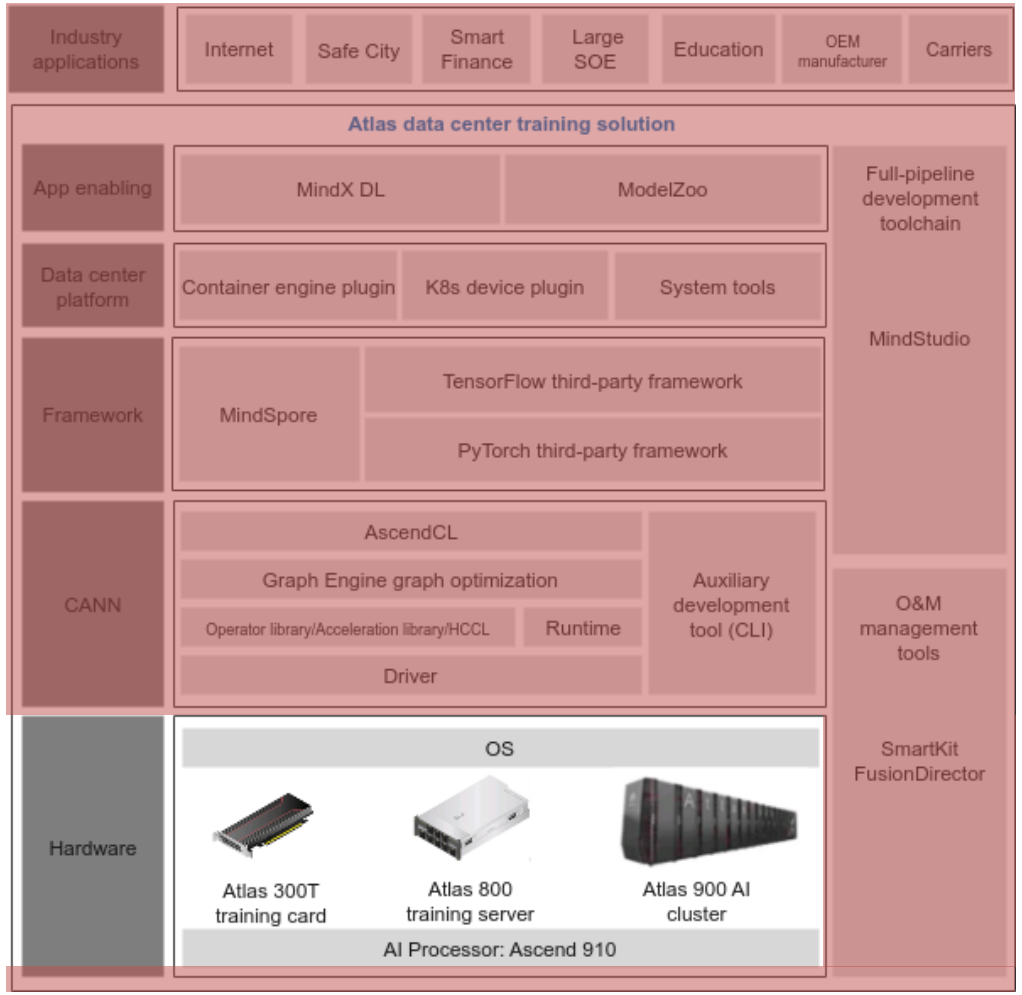
Arquitectura del ecosistema. Componentes



Capa	Componente	Descripción
CANN	AscendCL, GE, Librería de operadores / aceleradores HCCL, Runtime y Controlador	●El lenguaje de cómputo Ascend (AscendCL) incluye librerías C++ y APIs Phyton para que el usuario entrene las redes neuronales, gestione los dispositivos, la memoria, cargue los modelos y los ejecute al igual que los operadores. ●Durante el entrenamiento del modelo, AscendCL invoca a las API que proporciona el ejecutor el Motor Gráfico (GE) para compilar el modelo, y carga el modelo compilado y optimizado en el procesador Ascend de IA a través del Runtime para su cálculo. ●La Librería de operadores en el modelo de red incluye operadores para Caffe y TensroFlow. Se proporciona una librería independiente de aceleración, representada en las APIs de AscendCL. Por ejemplo: La API de multiplicación de matrices.. ●La Librería de Comunicación Colectiva Huawei (HCCL) se basa en el conjunto de comunicación del procesador Ascend IA. La HCCL incluye elementos para un solo servidor o varios servidores y dispositivos y la forma en la que se comunican sobre enlaces de alta velocidad PCIe, HCCS, y RoCE, con lo que se optimizan las etapas de entrenamiento. ●Runtime: Provee funciones tales como gestión de la memoria del chip y gestión de dispositivos ●Controlador: proporciona las interfaces para la ejecución en tiempo real en los dispositivos.
	Herramientas auxiliares de desarrollo (CLI)	Herramientas adicionales para el desarrollo del modelo o servicios, incluyendo herramientas de comparación precisas, herramientas de operadores y de depuración de código

Confidencial UNAM – Huawei
Elaborado por Fabián Romo Zamudio

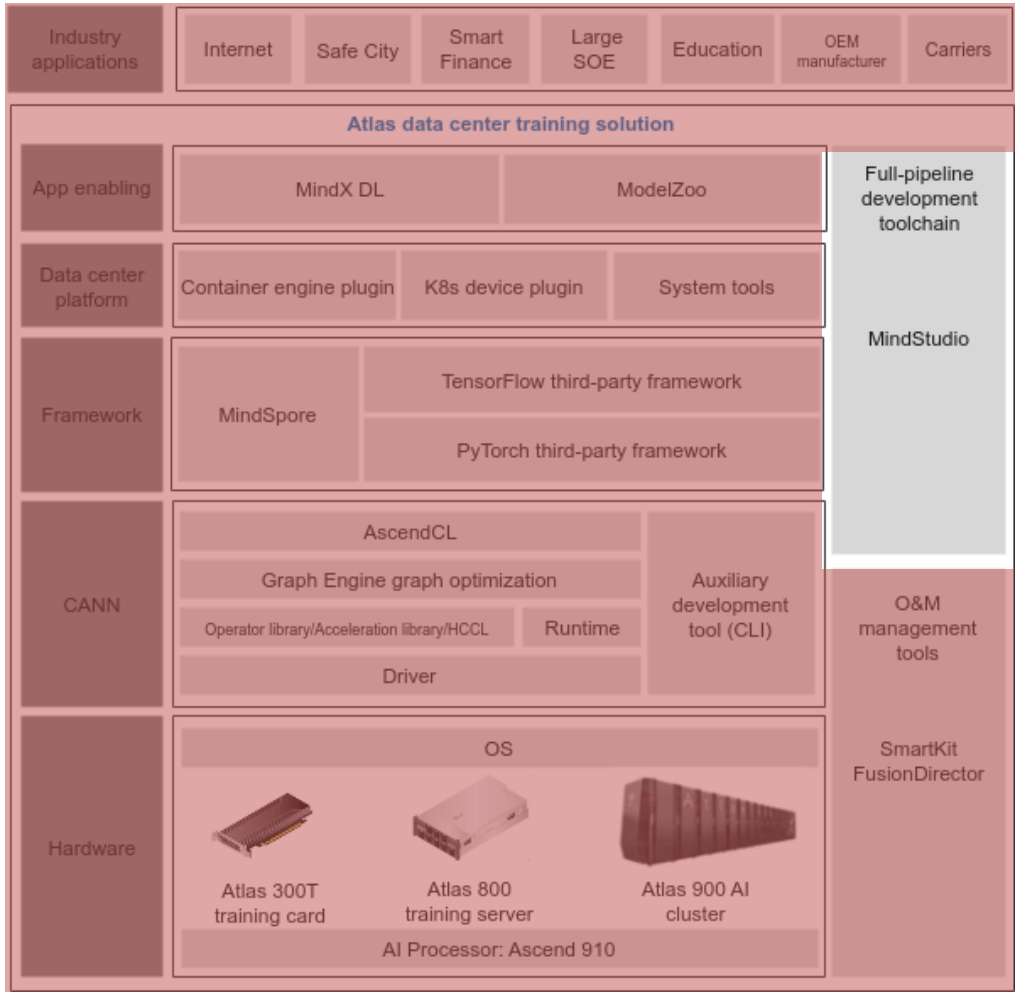
Arquitectura del ecosistema. Componentes



Capa	Componente	Descripción
Hardware	Tarjetas y servidores de entrenamiento	El hardware de entrenamiento, como la base de la capacidad computacional de los procesadores Ascend de IA, realiza los cálculos computacionales de las matrices en las redes neuronales, el cómputo en general de los operadores de control, escalares y vectoriales, así como el preprocesamiento de imagen y video El CANN garantiza la ejecución del cómputo para redes neuronales profundas (NN).

Confidencial UNAM – Huawei
Elaborado por Fabián Romo Zamudio

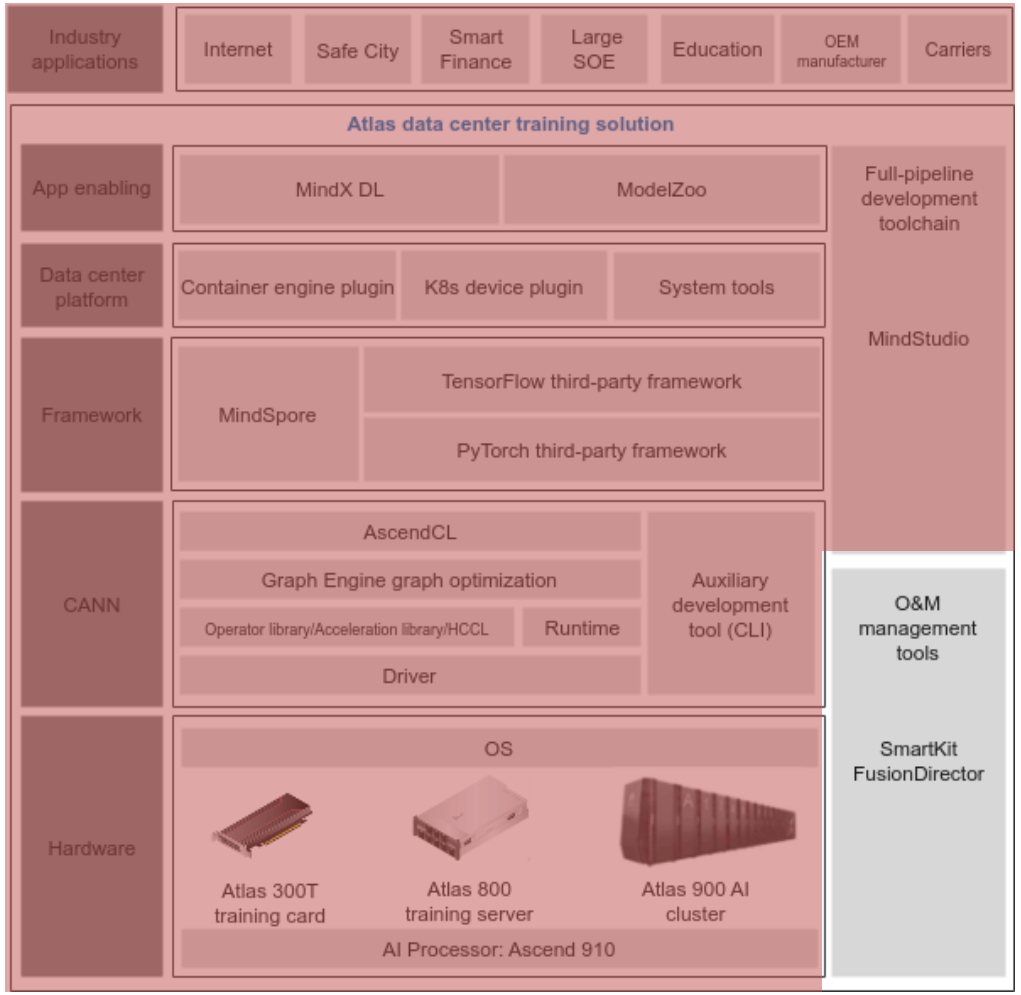
Arquitectura del ecosistema. Componentes



Capa	Componente	Descripción
Herramienta integral para desarrollo	MindStudio	Facilita un desarrollo simplificado e integral, incorporando los operadores, modelos y aplicaciones disponibles.

Confidencial UNAM – Huawei
Elaborado por Fabián Romo Zamudio

Arquitectura del ecosistema. Componentes

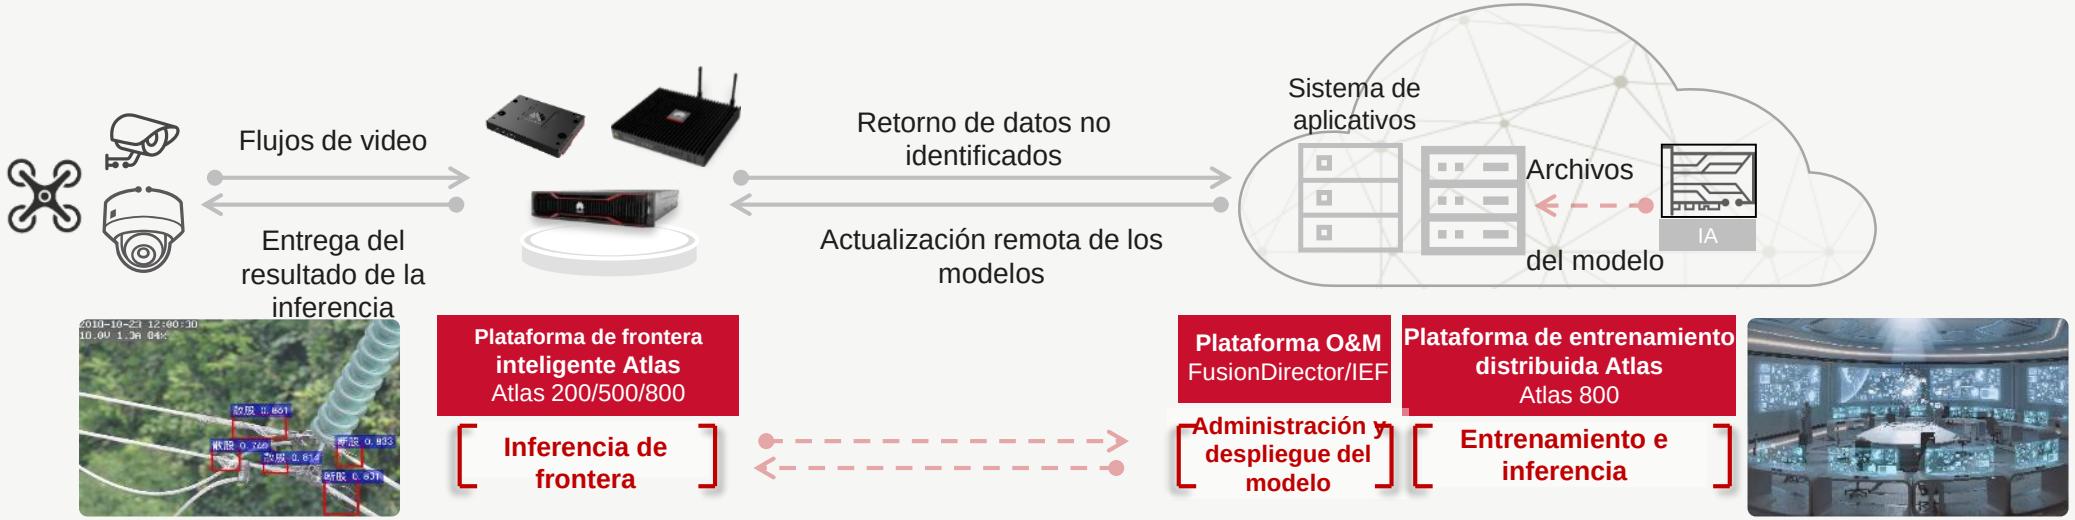


Capa	Componente	Descripción
Herramientas de operación y administración	SmartKit	Sirve para desarrollar, mantener y actualizar los dispositivos de entrenamiento en modo por bloques, simplificando las operaciones y mejorando la eficiencia.
	Fusion Director	Es el software de administración para una operación y administración inteligente durante todo el ciclo de vida del servidor. Facilita el manejo de versiones, desarrollos, recursos, control de energía y gestión de fallas. Incluye una interfaz visual (GUI) para la operación y administración

Confidencial UNAM – Huawei
Elaborado por Fabián Romo Zamudio

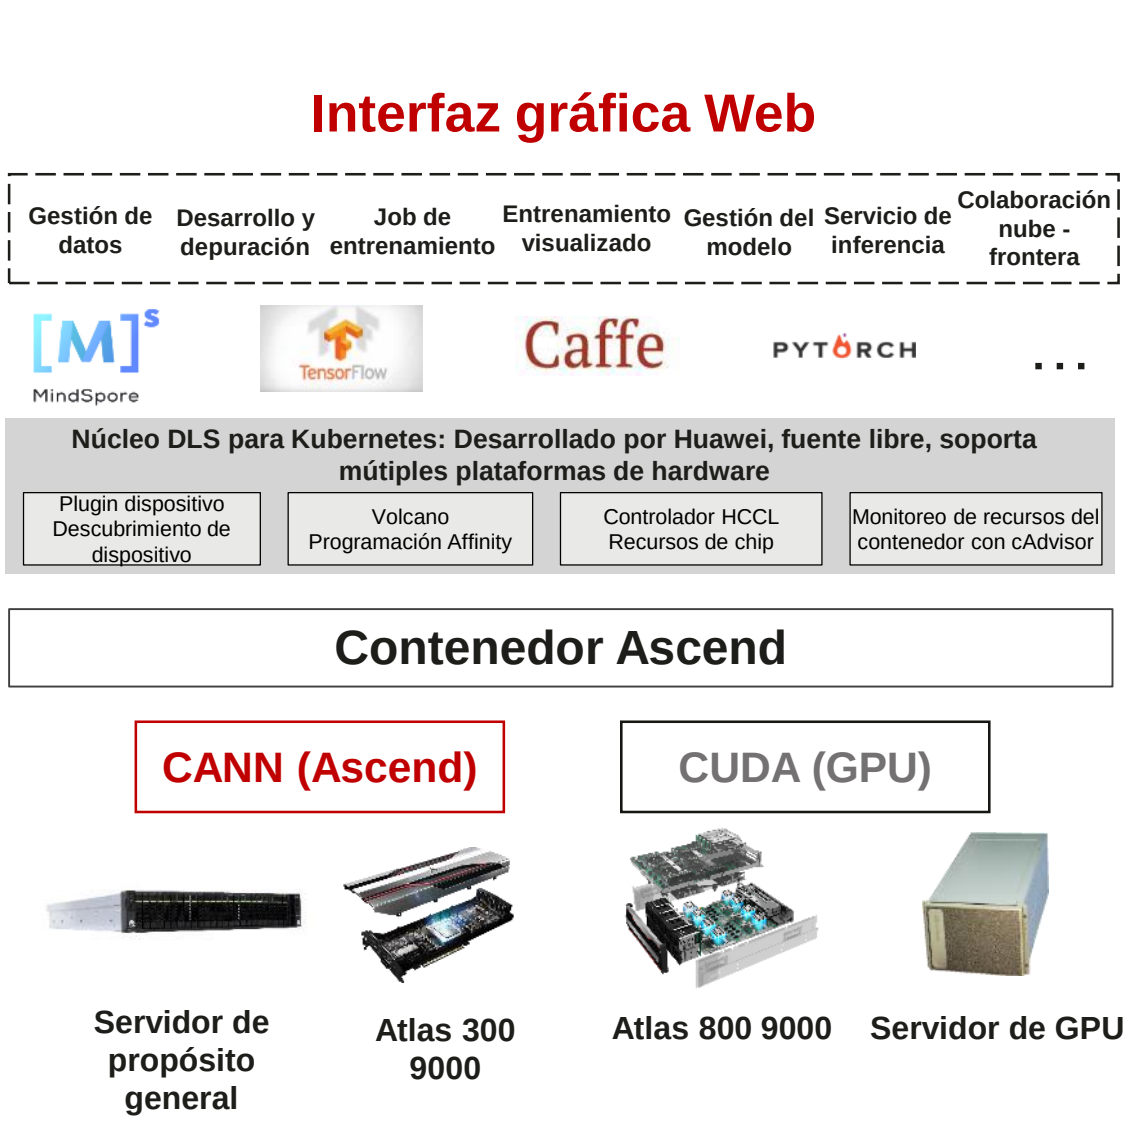
Colaboración dispositivo – frontera – nube, mejor experiencia para los desarrolladores y sus grupos de trabajo

Entrenamiento continuo desde el dispositivo al equipo de frontera y el centro de datos, para la actualización frecuente del modelo



	Desarrollo unificado	Operación y administración unificados	Seguridad extendida
Atlas	• La arquitectura unificada de desarrollo basada en Da Vinci y CANN, permite **desarrollar una vez y desplegar en múltiples sitios**	• FusionDirector administra hasta **50,000 nodos**, **maneja dispositivos centrales y de frontera**, y aplica de forma remota los modelos, a la vez que actualiza lo dispositivos	• Transmisión por canal encriptado • **Cifrado del modelo, doble seguridad**
Soluciones de la industria	• Los equipos de frontera y de los centros de daros usan arquitecturas de desarrollo distintas. **Los modelos no se pueden transferir libremente, lo que requiere de un segundo desarrollo**	• **Sin herramientas de operación y gestión (O&M)**; solo proporcionan APIs, por lo que los clientes necesitan desarrollar más APIs por ellos mismos	• **Sin motor de encriptamiento / desencriptamiento**; tampoco se encriptan los modelos.

Arquitectura de referencia de fuente libre para facilitar el funcionamiento del ecosistema

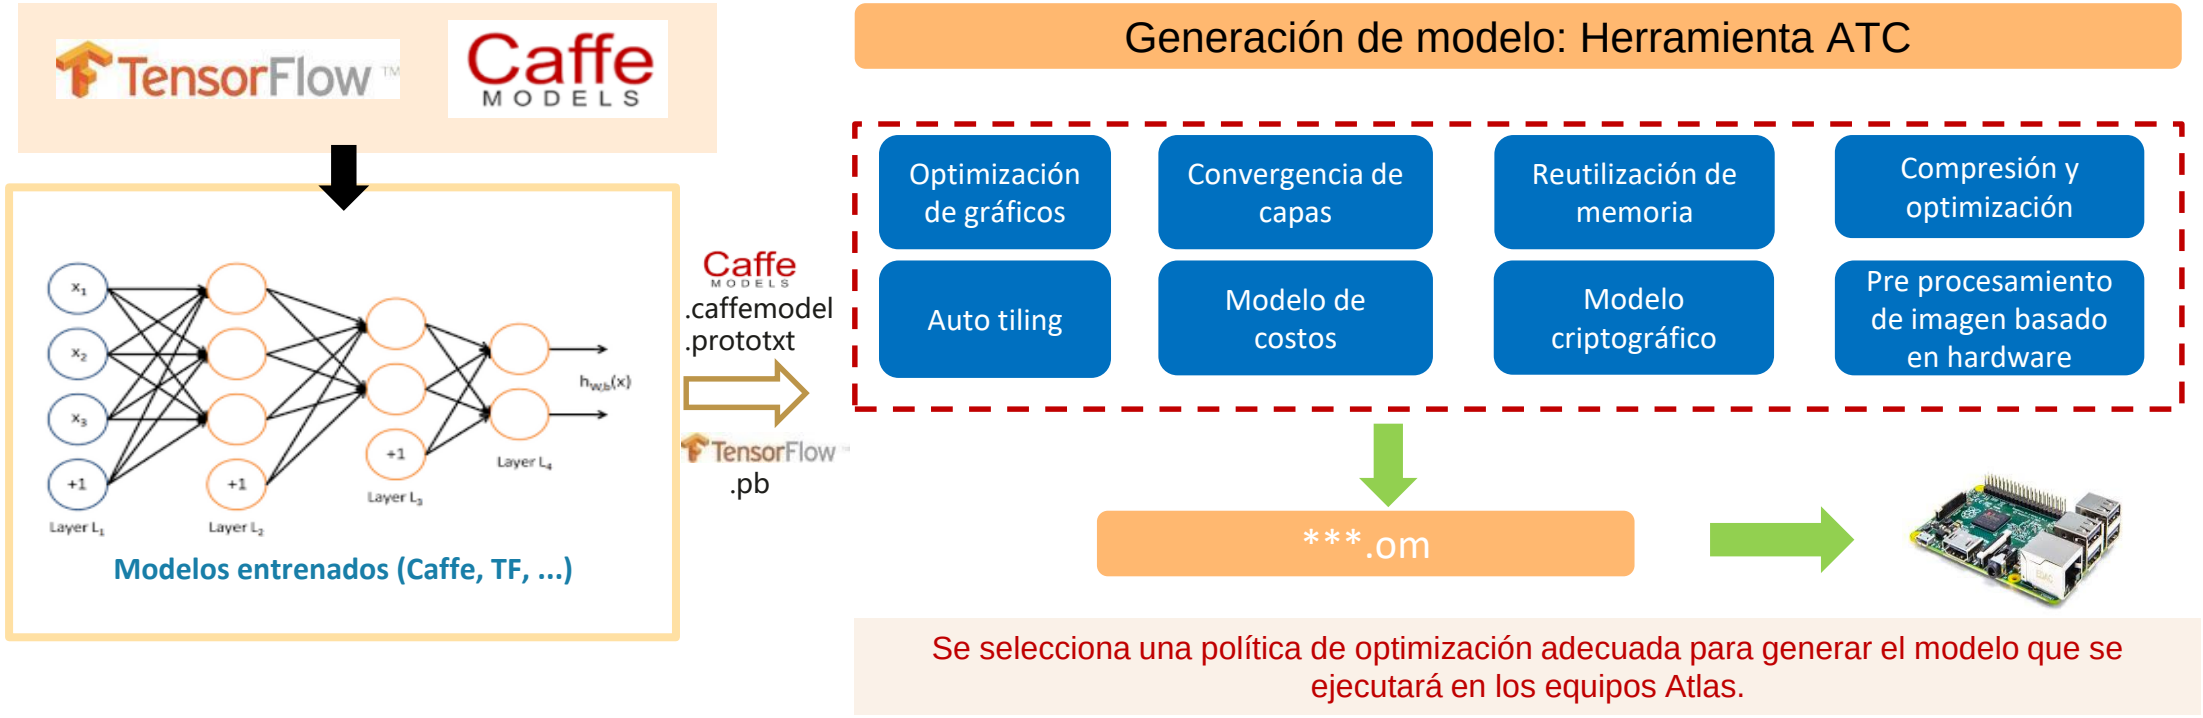


Arquitectura de referencia

Ecosistema abierto, incluye referencia para el diseño de una plataforma comercial de entrenamiento por terceros. Facilita desarrollos adaptados a las necesidades de socios y clientes

- **Administración de clúster heterogéneo:** Soporta la administración unificada de clústers heterogéneos con diversos tipos de cómputo, tales como NPU, GPU y CPU
- **Núcleo DLS:** Componente básico de alto rendimiento, **código de fuente libre**, soporta desarrollo secundario por proveedores independientes de software (ISV)
- **Entrenamiento e inferencia unificados: La gestión unificada de los servidores Atlas 800 (entrenamiento e inferencia)** se combina con los procesos unificados de entrenamiento en inferencia que se apoyan en los procesadores Ascend
- **Programación de entrenamiento de alto rendimiento:** Soporta la programación de grandes volúmenes de grupos datos, **mejorando la eficiencia de programación en un 30%**
- **Colaboración nube - frontera:** Procesamiento de IA basado en la colaboración nube – frontera, con entrenamiento en la nube e inferencia en la frontera. Se pueden liberar, actualizar y enviar los modelos para constituir un esquema de circuito cerrado

Herramienta de conversión de modelos, para validación de modelo



- **Generación del modelo (ATC - Ascend Tensor Compiler)**
  - Optimización del operador de programación, reorganización de pesos, optimización de memoria
  - El éxito en la conversión del modelo significa que los equipos Atlas soportan el modelo Si falla la conversión es posible que no se soporten algunos de los operadores del modelo original

Enfoque en los principales escenarios de aplicación en la industria. Algunos ejemplos de integración.

Industria, / Ámbito	Seguridad pública	Electricidad	Finanzas	Manufactura	Transportes	Internet	Telecomunicaciones …
	Reconocimiento facial | vehículos	Detección de líneas de transmisión | Monitoreo de subestación	Proyecciones inteligentes | OCR	Verificación de calidad | Visión de máquina	Tráfico de carreteras | Transporte ferroviario	Recomendaciones precisas | Revisión de contenido	Servicio Inteligente al Cliente | MEC
Aplicación	Reconocimiento de imágenes Análisis de secuencias	Análisis de imágenes Predicción de secuencias	Procesamiento en nube Imágenes medicas	Compresión de video Reconocimiento de caracteres	Reconocimiento de voz Traducción de máquina	Gráficos de conocimiento Toma inteligente de decisiones	Revisión de contenido Recomendaciones de búsqueda
Modelo	Clasificación / reconocimiento imágenes: ResNet, ResNeXt, Incepción, MobileNet, VGG, EfficientNet, AlexNet, GoogleNet, DenseNet, SqueezeNet	Detección de objetos: FasterRCNN, Yolo V1/2/3, SSD, RetinaNet, 3D DCNN, FCN	Segmentación de imagen: SegNet, MaskRCNN, UNet, DeepLab, Unet-3D	Voz: DFCNN, DeepSpeech, Tacotron, WaveNet, MuseNet	Comprensión semántica: BERT, Transformer, LSTM, GPT, Word2Vec	Sistema de recomendaciones: Wide&Deep, DeepFM	Sin soporte, Soportado 2022, Soporte futuro 2022
Vinculación	Esquema de desarrollo, Controlador	ACL, Tiempo real	Librerías, API de gestión	Lenguaje de desarrollo, Compilador	Motor gráfico, Depurador	Optimización gráfica, Perfilador	Kit de desarrollo, Desarrollo de operadores
Kernel	Programador de tareas	Controlador	Conjunto de instrucciones virtuales HTX	Optimización de instrucciones	Compilador de backend	Gestor de almacenamiento	
Hardware y arquitectura	Dispositivo: Chips de dispositivos inteligentes 2–4 TOPS INT8; Teléfonos inteligentes < 2 TOPS INT8	Frontera: Atlas 200 22 TOPS INT8; Atlas 500 22 TOPS INT8; Atlas 300 88 TOPS INT8	Nube: Atlas 800 704 TOPS INT8; Atlas 800 2 PFLOPS FP16; Atlas 300T 256 TFLOPS FP16; Atlas 900 256–1024 PFLOPS FP16				











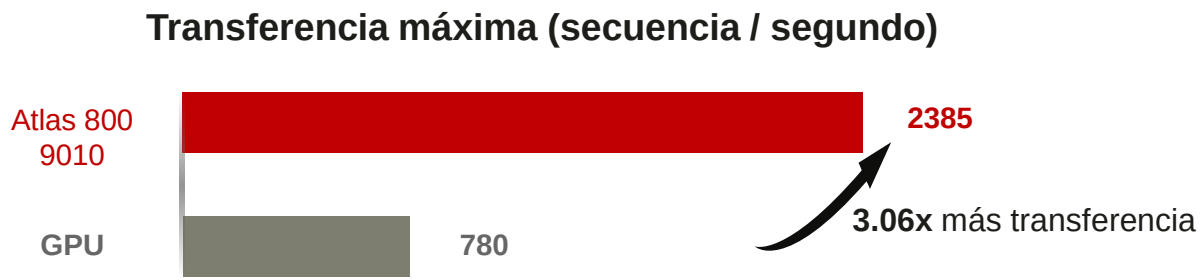


Ascend 310 — Arquitectura Da Vinci — Ascend 910

Ejemplo de rendimiento. Modelo BERT-LARGE
Los equipos Atlas reportan 3 veces más rendimiento que las GPU

Prueba del desempeño de red. Modelo BERT-LARGE						
Escenario de la prueba				**GPU Modelo: Tesla V100-SXM2-16GB**	**Atlas 800**	**Rendimiento Atlas / Rendimiento GPU**
Grupo de datos	**Longitud de secuencia**	**Dispositivo**	**Tamaño de lote**	**Transferencia (secuencias / segundo)**	**Transferencia (secuencias / segundo)**	
En_Wiki	128	1	16	87	169.7	1.95
		8	16	565	1052	1.86
		1	28	117	217	1.85
		8	28	780	1562	2.00
		1	64	Desborde de memoria	299	2.56
		8	64		2232	2.86
		1	96		312	2.67
		8	96		2385	3.06

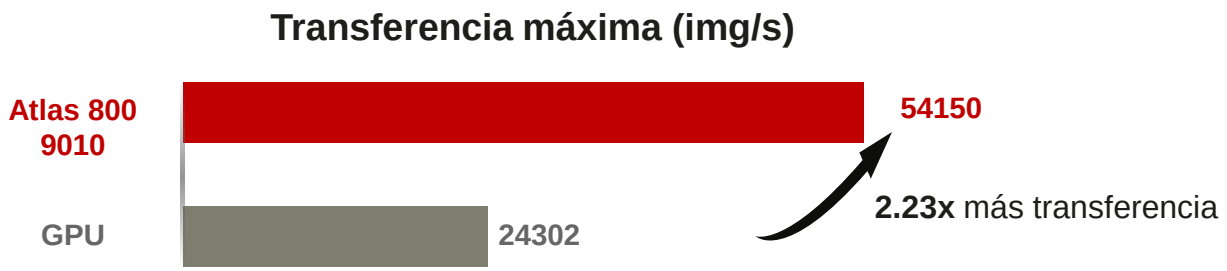
Esquema: TensorFlow 1.15; Precisión de entrenamiento: FP16 precisión hibrida; Optimizador: **BERT-Adam**



Ejemplo de rendimiento. Modelo ResNet-50
Los equipos Atlas tienen 2.2x mayor transferencia y 1.5x mayor linealidad sobre los GPUs

Prueba típica del modelo (rendimiento de red ResNet-50)								
Escenario de prueba	GPU de la competencia (NVLink) Modelo: Tesla V100-SXM2-32GB				Atlas 800 TF1.15			
	Datos de la prueba				Datos de la prueba			
Número de dispositivos en la red	Tamaño del lote	FP16 (img/s)	FP16+XLA (img/s)	Linealidad	Tamaño del lote	FP16 (img/s)	**Rendimiento Atlas / rendimiento GPU**	**Linealidad**
1	256	787	1276		32	1846	**145%**	
8	256	5774	8675	85%	32	14060	**162%**	**95%**
16	256	10471	13191	65%	32	27731	**210%**	**94%**
32	256	19373	24302	60%	32	54150	**223%**	**92%**

Esquema: TensorFlow; Conjunto de datos: ImageNet2010; Precisión del entrenamiento: precision híbrida



Abriendo el hardware, haciendo software libre y empoderando a los socios tecnológicos.

Socios | Huawei



Portabilidad de apps	Huawei soporta la portabilidad de las principales apps y del software sin cargo
Software de fuente abierta	• Esquema de fuente abierta para IA (MindSpore) • Base de datos de fuente abierta (GaussDB OLTP versión de un solo equipo), permite a socios tecnológicos desarrollar sus propias versiones de bases de datos • Sistema operativo de fuente abierta, que permite a los socios tecnológicos desarrollar sus propios productos
Hardware abierto	• Tarjetas aceleradoras y módulos Atlas, que los socios tecnológicos pueden usar para el desarrollo de soluciones inteligentes para la industria • Tarjetas madre y componentes como SSD, NIC y RAID, que los desarrolladores pueden usar para crear sus propios productos
Enfoque de negocio	Innovación en arquitectura; Investigación y desarrollo de procesadores; Servicios de nube

Confidencial UNAM – Huawei
Elaborado por Fabián Romo Zamudio

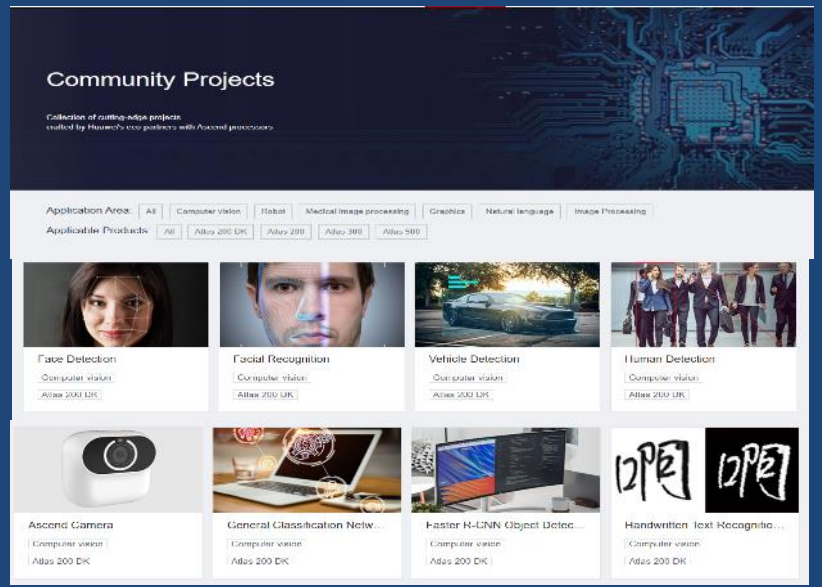
DGTIC UNAM
DIRECCIÓN GENERAL DE CÓMPUTO Y DE TECNOLOGÍAS DE INFORMACIÓN Y COMUNICACIÓN

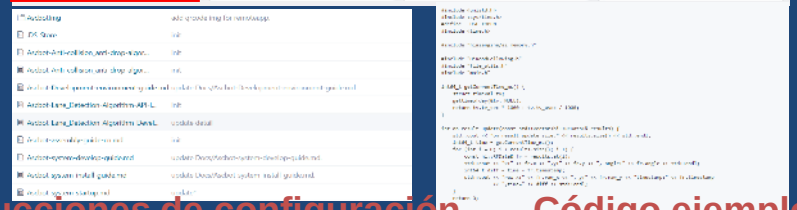
HUAWEI

Vinculación de los desarrolladores en la comunidad Ascend

Comunidad de desarrolladores Huawei Ascend: **https://www.huaweicloud.com/intl/en-us/ascend/apps**

Proyectos de la comunidad con Código de Fuente libre, instrucciones de configuración

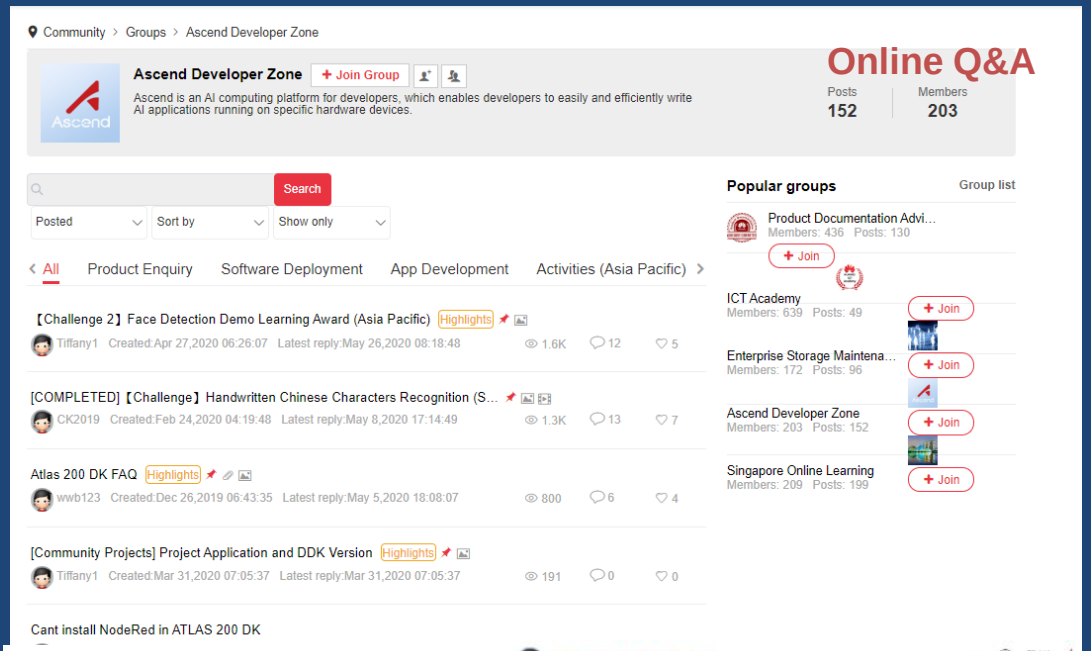


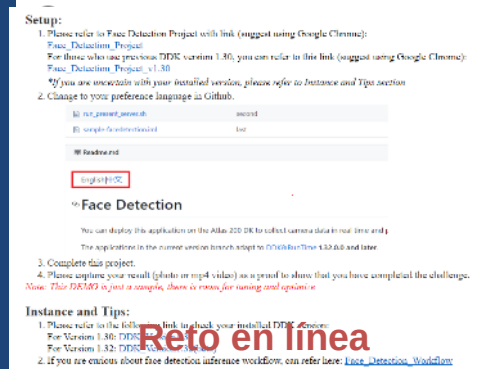


Instrucciones de configuración

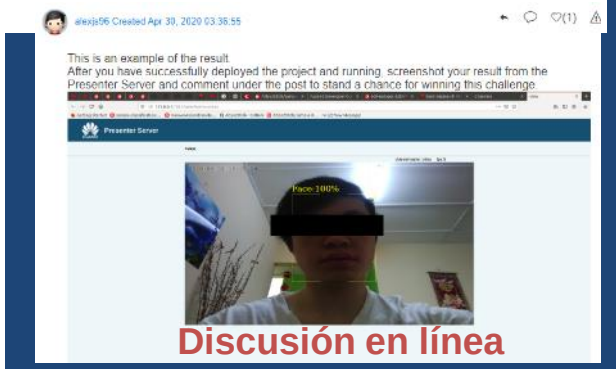
Código ejemplo

Grupo en línea de desarolladores





Reto en línea



Discusión en línea

Esquema de certificación Huawei en IA

HCIP AI EI Desarrollador

HUAWEI CLOUD
ModelArts
MindSpore

- Ingeniero en implementación de algoritmos de IA
- Ingeniero en algoritmos de entrenamiento de IA
- Ingeniero en algoritmos de aplicaciones de IA

HCIP Red de IA y Desarrollador de IA

HUAWEI CLOUD
ModelArts
Gobernanza de lago de datos

- Ingeniero en planeación de redes
- Ingeniero en servicios de redes

HCIP AI Desarrollador HiAI

Mobile terminal HiAI

- Ingeniero en el Desarrollo de aplicaciones móviles.
- Ingeniero en aplicaciones de IA para dispositivos inteligentes

HCIP Desarrollador en IA Ascend

Ascend
Atlas
CANN

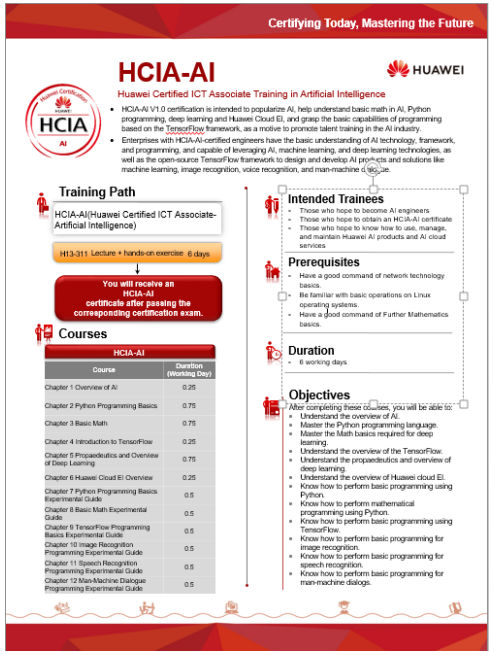
- Ingeniero en Desarrollo de IA con Ascend
- Ingeniero en aplicaciones de IA en Ascend

HUAWEI CLOUD
ModelArts
Ascend
Atlas
CANN
HiAI terminal móvil
MindSpore de Fuente libre

HCIA IA

- Ingeniero junior en IA
- Administrador de proyectos de IA
- Ingeniero verificador de algoritmos para IA



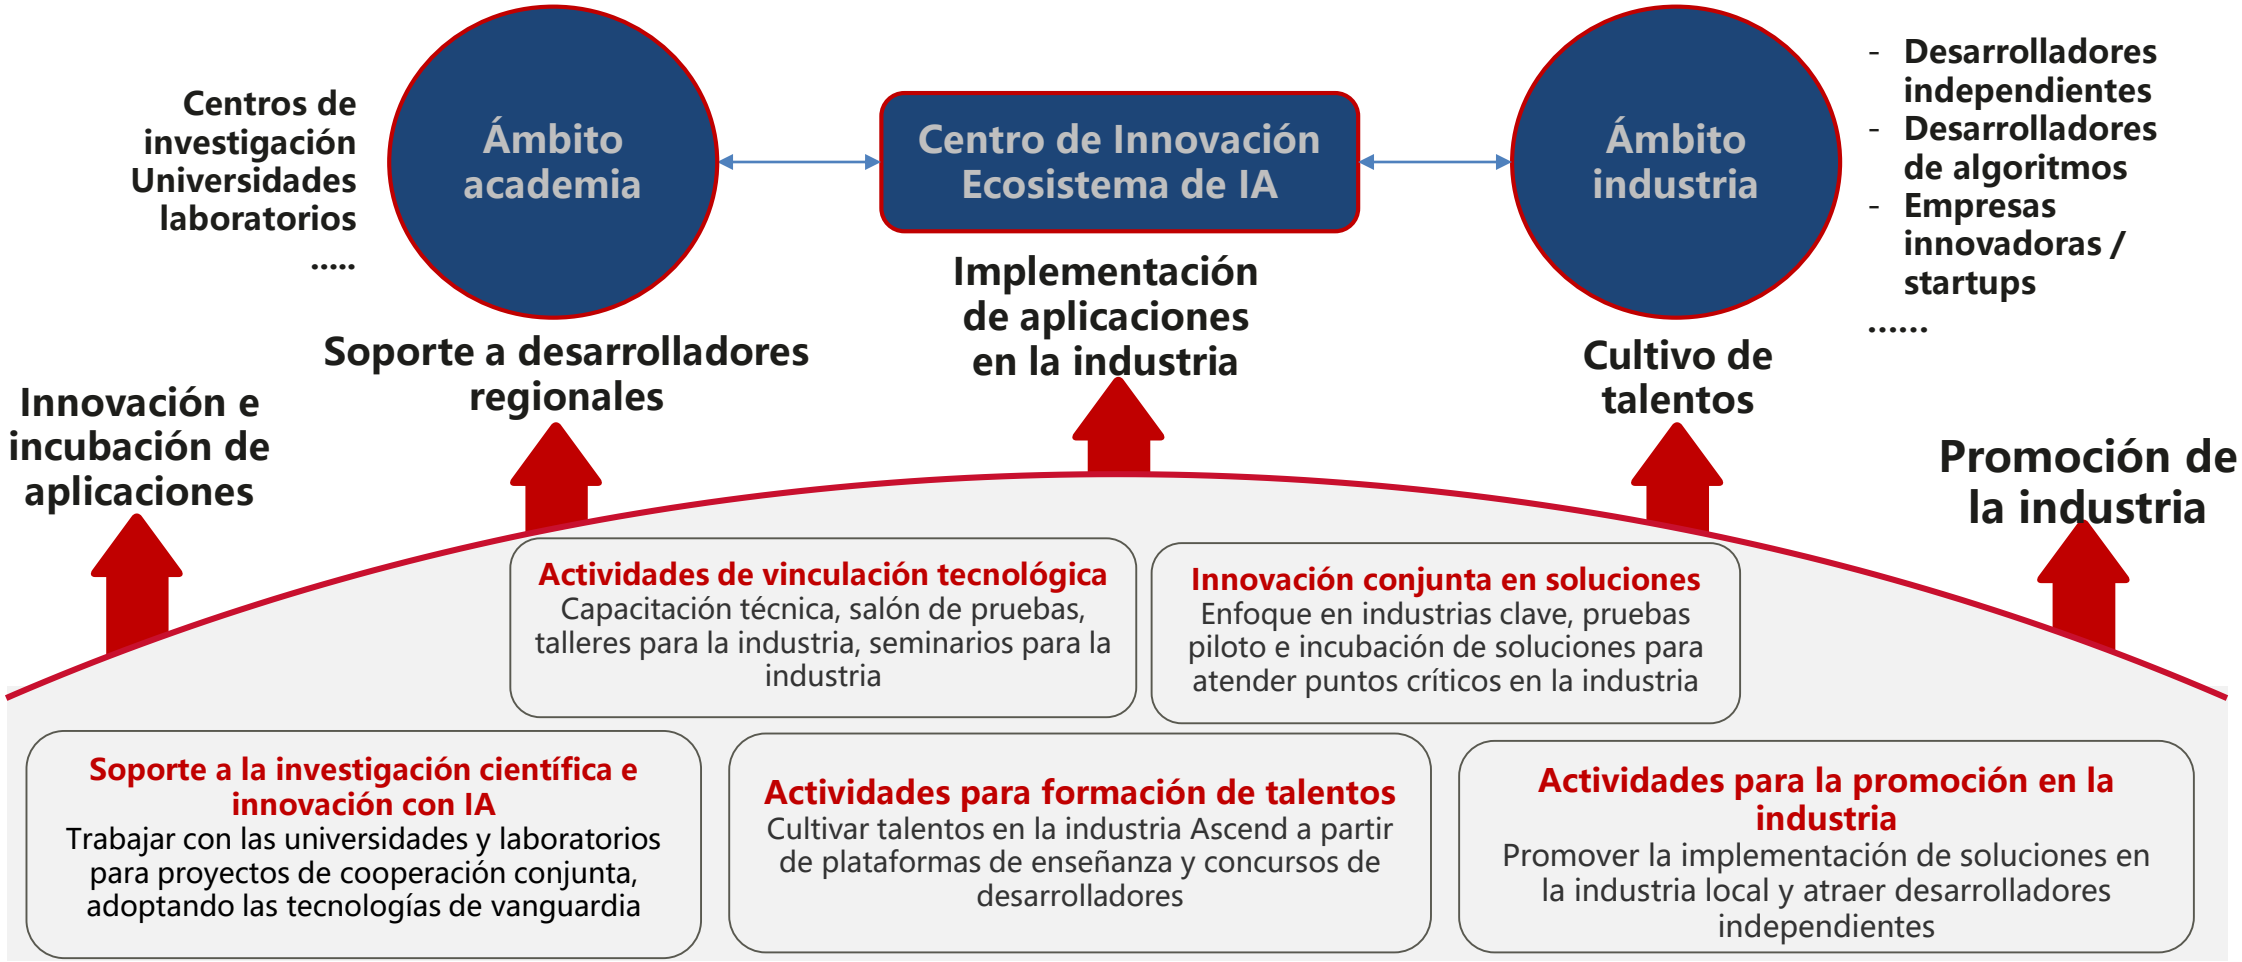


Confidencial UNAM – Huawei
Elaborado por Fabián Romo Zamudio

DGTIC UNAM
DIRECCIÓN GENERAL DE CÓMPUTO Y DE TECNOLOGÍAS DE INFORMACIÓN Y COMUNICACIÓN

HUAWEI

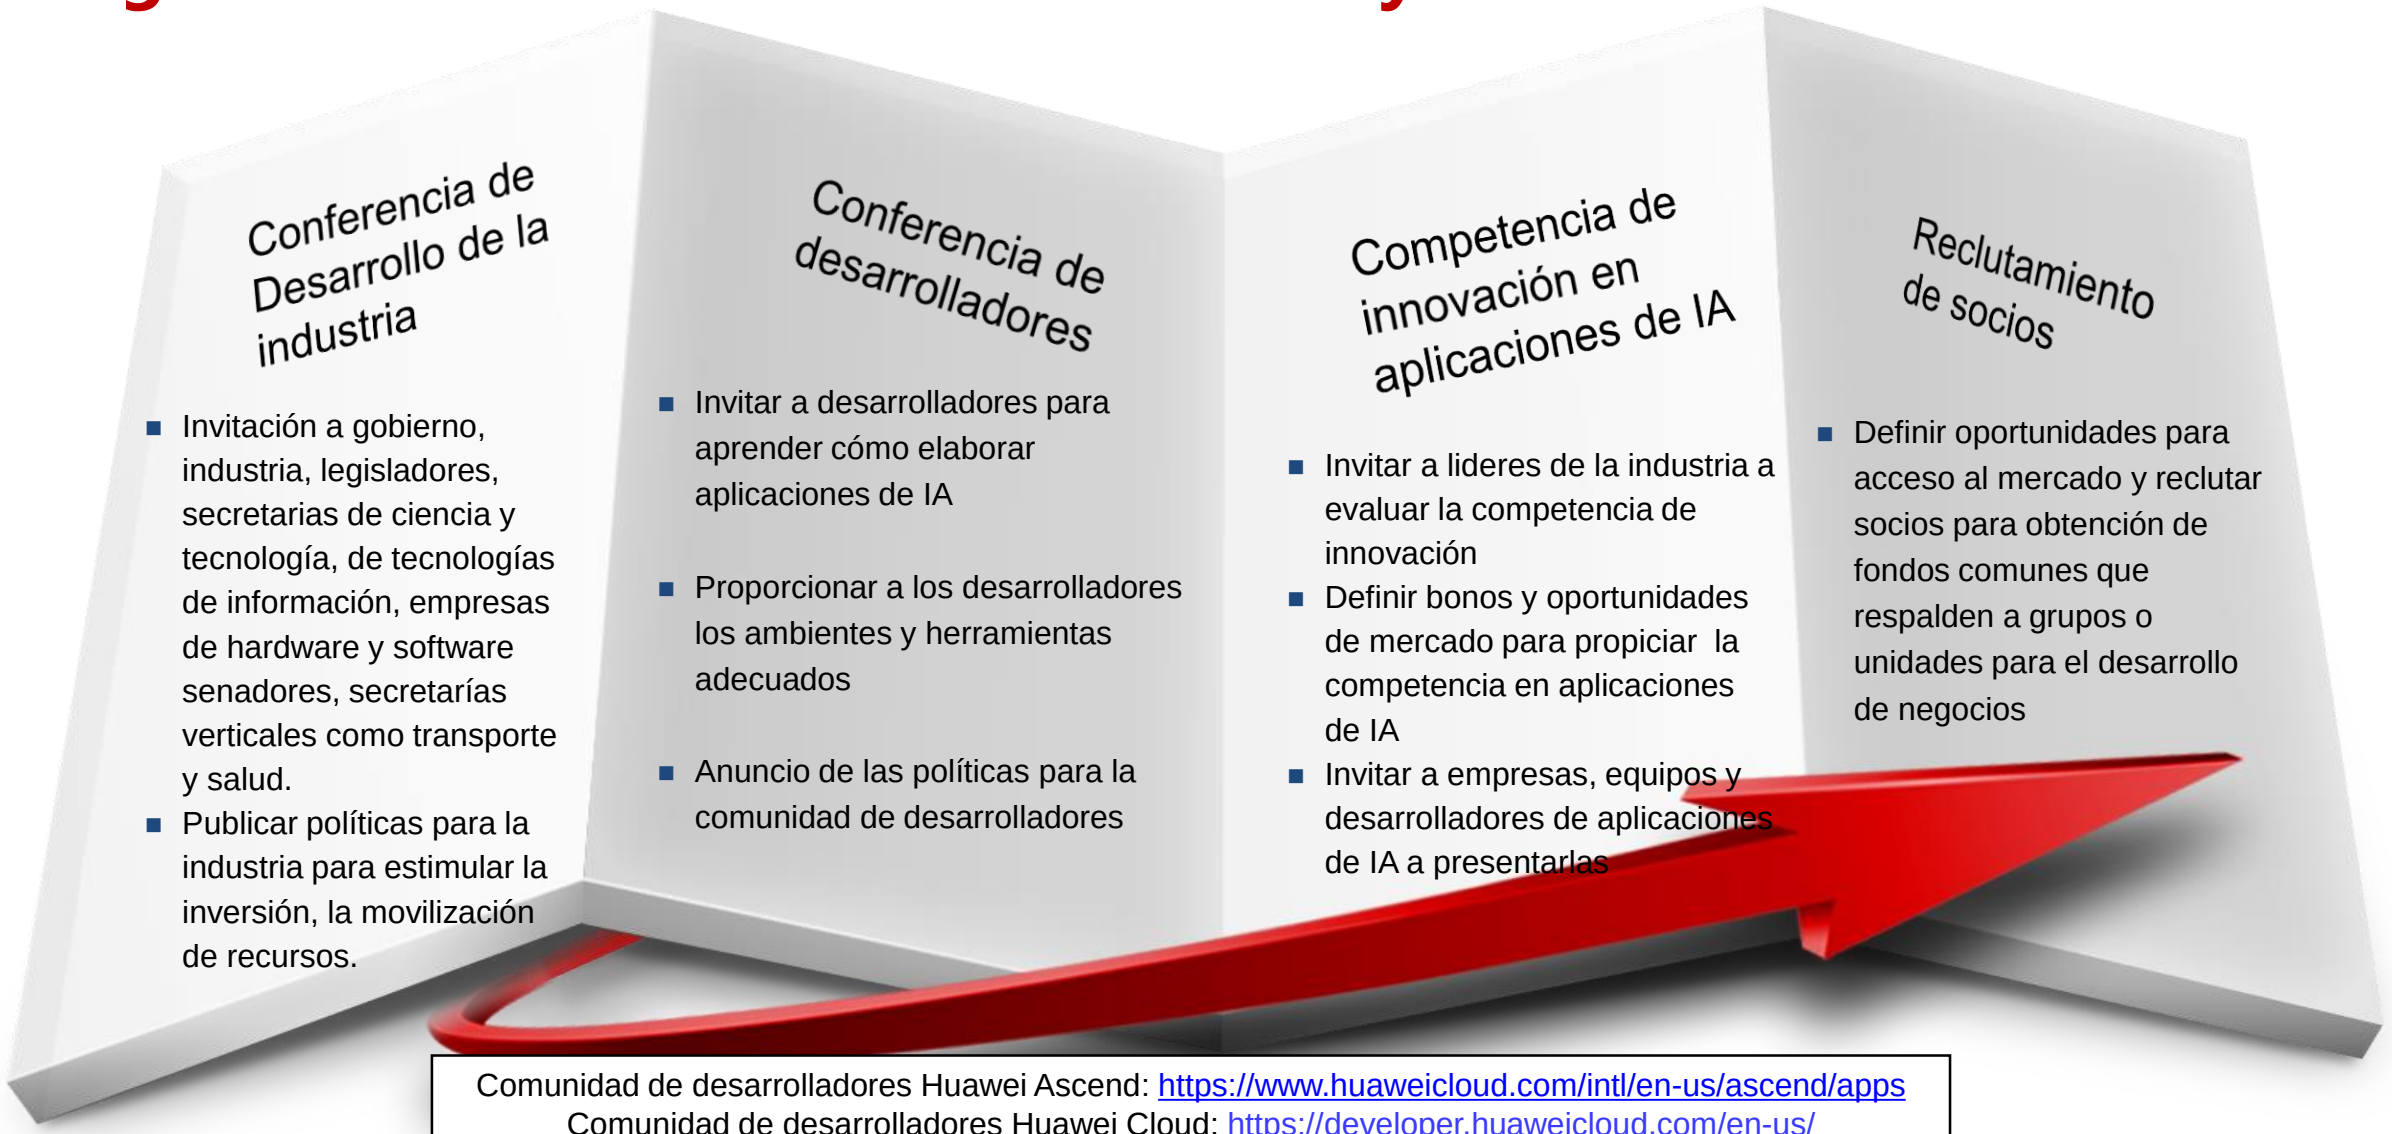
Vinculación de la IA con las PyMES y promover su crecimiento en la industria



Basado en el ecosistema Huawei de innovación en IA y las políticas de vinculación de desarrolladores, dar el soporte al desarrollo de la industria de IA en México

Confidencial UNAM – Huawei
Elaborado por Fabián Romo Zamudio

Programa de desarrollo del ecosistema y la industria



Conferencia de Desarrollo de la industria

- Invitación a gobierno, industria, legisladores, secretarias de ciencia y tecnología, de tecnologías de información, empresas de hardware y software senadores, secretarías verticales como transporte y salud.
- Publicar políticas para la industria para estimular la inversión, la movilización de recursos.

Conferencia de desarrolladores

- Invitar a desarrolladores para aprender cómo elaborar aplicaciones de IA
- Proporcionar a los desarrolladores los ambientes y herramientas adecuados
- Anuncio de las políticas para la comunidad de desarrolladores

Competencia de innovación en aplicaciones de IA

- Invitar a lideres de la industria a evaluar la competencia de innovación
- Definir bonos y oportunidades de mercado para propiciar la competencia en aplicaciones de IA
- Invitar a empresas, equipos y desarrolladores de aplicaciones de IA a presentarlas

Reclutamiento de socios

- Definir oportunidades para acceso al mercado y reclutar socios para obtención de fondos comunes que respalden a grupos o unidades para el desarrollo de negocios

Comunidad de desarrolladores Huawei Ascend: https://www.huaweicloud.com/intl/en-us/ascend/apps
Comunidad de desarrolladores Huawei Cloud: https://developer.huaweicloud.com/en-us/
Comunidad de desarrolladores Huawei Kunpeng: https://www.hikunpeng.com/developer

DGTIC UNAM DIRECCIÓN GENERAL DE CÓMPUTO Y DE TECNOLOGÍAS DE INFORMACIÓN Y COMUNICACIÓN

HUAWEI

Construir un entorno de socios completo para soportar un ecosistema en todos los niveles y todos los escenarios

Programa de socios tecnológicos Ascend

- Para socios
- Para desarrolladores
- Para universidades
- Para emprendedores

Para socios:

- Consultoría e integración de soluciones **C&SI**
- Integradores independientes de software **ISV**
- Integradores independientes de hardware **IHV**
- Proveedor de servicios en la Nube **XaaS**
- Fabricante de equipamiento original **OEM**
- Fabricante de diseño original **ODM**

+

Programas independientes del ecosistema por los socios tecnológicos

Impulsar a los socios a liberar programas independientes del ecosistema para Ascend.
Disfrutar de los derechos y beneficios de ambos ecosistemas.

- Para la nube Huawei
- Para visión de máquina
- Para los socios

Mecanismo amplio para incentivar un ecosistema próspero Ascend.

Fase de aprendizaje (LDF: Learning Development Fund)	Fase de desarrollo (PDF: Product Development Fund)	Fase de lanzamiento (MDF: Market Development Fund)	Fase de comercialización (SDF: Sales Development Fund)
Entrenar talento	Recursos de nube	Dispositivos de ejemplo	NRE
		PAE/FAE	Mercados
			MDF
			Incentivar el beneficio directo
			Incentivar el beneficio indirecto

DGTIC UNAM DIRECCIÓN GENERAL DE CÓMPUTO Y DE TECNOLOGÍAS DE INFORMACIÓN Y COMUNICACIÓN
HUAWEI

A través de la competencia para el Desarrollo de aplicaciones nativas para la nube con 4 patrocinadores, enriquecer el ecosistema de software, expandir el mercado y abrir nuevas líneas de acción

Cooperación de 4 capas de socios para la competencia de aplicaciones nativas en la nube





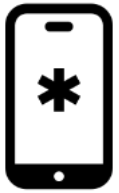


Corporación / institución



Inversión





Aplicaciones móviles



Aplicaciones de video



Aplicaciones 5G2B

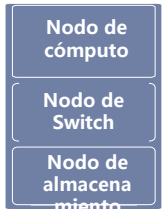




Repositorio de recursos



Nube



Cómputo en clúster







Datos



Usuarios



Plataformas

Corporaciones - instituciones: seleccionar emprendedores en los cuales invertir

- Seleccionar los líderes de dos empresas VC para ser jueces de la competencia
- La competencia por la inversión que ganarán las aplicaciones nativas en la red . Las aplicaciones podrán ejecutarse en las plataformas de empresas de telecomunicaciones y obtener ingresos

Emprendedores: Organizar competencias para ayudar a emprendedores a transformar sus ideas en aplicaciones

- Organizar audiciones de la competencia, evaluaciones, desarrollo de negocios y distribución de fondos.
- Proporcionar una plataforma amplia para emprendedores y convertir sus ideas en aplicaciones prácticas y atraer a más colaboradores a los desarrollos,

Huawei: APIs abiertas y dar soporte técnico

- APIs abiertas para repositorios de recursos, nube, cómputo en clúster Seleccionar dos personas como asesores.
- Establecer un equipo de profesionales para la vinculación con emprendedores y dar soporte técnico.
- Ayudar a las empresas a disponer de plataformas de nube más eficientes,

Empresas de telecomunicaciones: Proporcionar una plataforma para aplicaciones obtener ganancias y beneficiar a los usuarios.

- Líderes de las telco (CMOs y CIOs) como jueces.
- Proporcionar datos de los usuarios a los emprendedores para desarrollar aplicaciones y proporcionar una plataforma para aplicaciones de software.
- Generar ingresos en las aplicaciones y compartirlo para beneficiar el ecosistema y a los usuarios.

Gracias

把数字世界带入每个人、每个家庭、
每个组织，构建万物互联的智能世界。

Bring digital to every person, home, and organization for a fully connected, intelligent world.

Copyright © 2020 – 2023 Huawei Technologies Co., Ltd.
All Rights Reserved.

Universidad Nacional Autónoma de México

The information in this document may contain predictive statements including, without limitation, statements regarding the future financial and operating results, future product portfolio, new technology, etc. There are a number of factors that could cause actual results and developments to differ materially from those expressed or implied in the predictive statements. Therefore, such information is provided for reference purpose only and constitutes neither an offer nor an acceptance. Huawei may change the information at any time without notice.

DGTIC UNAM
DIRECCIÓN GENERAL DE CÓMPUTO Y DE TECNOLOGÍAS DE INFORMACIÓN Y COMUNICACIÓN

HUAWEI