

Actividad 1: Conceptos generales de redes neuronales

En esta actividad vamos a revisar algunos de los conceptos básicos de las redes neuronales, pero no por ello menos importantes.

El dataset a utilizar es Fashion MNIST, un problema sencillo con imágenes pequeñas de ropa, pero más interesante que el dataset de MNIST. Puedes consultar más información sobre el dataset en este enlace.

El código utilizado para contestar tiene que quedar claramente reflejado en el Notebook. Puedes crear nuevas celdas si así lo deseas para estructurar tu código y sus salidas. A la hora de entregar el notebook, asegúrate de que los resultados de ejecutar tu código han quedado guardados (por ejemplo, a la hora de entregar una red neuronal tiene que verse claramente un log de los resultados de cada epoch).

In [1]:

```
import tensorflow as tf
print(tf.__version__)
```

2.8.0

In [2]:

En primer lugar vamos a importar el dataset Fashion MNIST recordad que este es uno de los dataset de entrenamiento que están guardados en keras) que es el que vamos a utilizar en esta actividad:

```
mnist = tf.keras.datasets.fashion_mnist
```

Llamar a **load_data** en este dataset nos dará dos conjuntos de datos, estos serán los valores de entrenamiento y prueba para los gráficos que contengan las imágenes de vestir y sus etiquetas.

Nota: Aunque en esta actividad lo veis de esta forma, también lo vais a poder encontrar con 4 variables de esta forma: training_images, training_labels, test_images, test_labels = mnist.load_data()

In [3]:

```
(training_images, training_labels), (test_images, test_labels) = mnist.load_data()
```

Antes de continuar vamos a dar un vistazo a nuestro dataset, para ello vamos a ver una imagen de entrenamiento y su etiqueta a clase.

In [4]:

```
import numpy as np
np.set_printoptions(linewidth=200)
img = plt.imread(training_images[0], cmap="gray") # recordad que siempre es preferible trabajar en blanco y negro
plt.imshow(img)
print(training_labels[0])
print(training_images[0])
```



0

Habéis notado que todos los valores numéricos están entre 0 y 255. Si estamos entrenando una red neuronal, una buena práctica es transformar todos los valores entre 0 y 1, un proceso llamado "normalización" y afortunadamente en Python es fácil normalizar una lista. Lo puedes hacer de esta manera:

In [5]:

```
training_images = training_images / 255.0
test_images = test_images / 255.0
```

Ahora vamos a definir el modelo, pero antes vamos a repasar algunos comandos y conceptos muy útiles:

- Sequential**: Se refiere a una secuencia de capas en la red neuronal
- Dense**: Hace una capa de neuronas
- Flatten**: Reduce las imágenes como eran las imágenes cuando las imprimiste para poder verlas? Un cuadrado. Flatten solo toma ese cuadrado y lo convierte en un vector de una dimensión.

Cada capa de neuronas necesita una función de activación. Normalmente se usa la función relu en las capas intermedias y softmax en la última capa

- Relu**: significa que "Si X>0 devuelve X, si no, devuelve 0", así que lo que hace es pasar sólo valores 0 o mayores a la siguiente capa de la red.
- Softmax** toma un conjunto de valores, y escoge el más grande.

Pregunta 1 (3.5 puntos) Utilizando Keras, y preparando los datos de X e y como fuera necesario, define y entrena una red neuronal que sea capaz de clasificar imágenes de Fashion MNIST con las siguientes características:

- Una hidden layer de tamaño 128, utilizando unidades sigmoid Optimizador Adam.
- Durante el entrenamiento, la red tiene que mostrar resultados de loss y accuracy por cada epoch.
- La red debe entrenar durante 10 epochs y batch size de 64.
- La última capa debe de ser una capa softmax.
- Tu red tendría que ser capaz de superar fácilmente 80% de accuracy.

In [6]:

```
## Tu código para la red neuronal de la pregunta 1 aquí ##
from tensorflow import keras
from tensorflow.keras import layers

model = keras.Sequential([
    keras.layers.Flatten(input_shape=(28, 28)),
    keras.layers.Dense(128, activation='sigmoid'),
    keras.layers.Dense(10, activation='softmax')
])

model.compile(loss = "sparse_categorical_crossentropy", optimizer="adam", metrics=["accuracy"])
model.fit(training_images, training_labels, batch_size = 64, epochs = 10)
```

Epoch 1/10 [=====] - 2s 2ms/step - loss: 0.5959 - accuracy: 0.8045
Epoch 2/10 [=====] - 2s 2ms/step - loss: 0.4104 - accuracy: 0.8537
Epoch 3/10 [=====] - 2s 2ms/step - loss: 0.3727 - accuracy: 0.8679
Epoch 4/10 [=====] - 2s 2ms/step - loss: 0.3310 - accuracy: 0.8805
Epoch 5/10 [=====] - 2s 2ms/step - loss: 0.3154 - accuracy: 0.8851
Epoch 6/10 [=====] - 2s 2ms/step - loss: 0.3021 - accuracy: 0.8904
Epoch 7/10 [=====] - 2s 2ms/step - loss: 0.2917 - accuracy: 0.8949
Epoch 8/10 [=====] - 2s 2ms/step - loss: 0.2821 - accuracy: 0.8973
Epoch 9/10 [=====] - 2s 2ms/step - loss: 0.2725 - accuracy: 0.8997
Epoch 10/10 [=====] - 2s 2ms/step - loss: 0.2623 - accuracy: 0.8997
Keras.callbacks.History at 0x1b90e31a91d>

In [7]:

```
## Tu código para la evaluación de la red neuronal de la pregunta 2 aquí ##
score = model.evaluate(test_images, test_labels)
```

313/313 [=====] - 1s 1ms/step - loss: 0.3432 - accuracy: 0.8729

Ahora vamos a explorar el código con una serie de ejercicios para alcanzar un grado de comprensión mayor sobre las redes neuronales y su entrenamiento.

Ejercicio 1: Funcionamiento de las predicción de la red neuronal

Para este primer ejercicio sigue los siguientes pasos:

In [11]:

```
## Tu código del clasificador de la pregunta 3 aquí ##
classifications = model.predict(test_images)
classifications[0]
```

Out [11]:

```
array([2.5140305e-05, 1.0595375e-07, 1.1928208e-05, 8.5256252e-06, 3.7316753e-05, 1.8894947e-02, 9.5701122e-05, 2.8292615e-02, 8.9763629e-04, 9.5168161e-01], dtype=float32)
```

Ejercicio 2: Impacto variar el número de neuronas en las capas ocultas

En este ejercicio vamos a experimentar con nuestra red neuronal cambiando el número de neuronas por 512 y por 1024. Para ello, utiliza la red neuronal de la pregunta 1, y su capa oculta cambia las 128 neuronas:

In [12]:

```
## Tu código para 512 neuronas aquí ##
model_2 = keras.Sequential([
    keras.layers.Flatten(input_shape=(28, 28)),
    keras.layers.Dense(512, activation='sigmoid'),
    keras.layers.Dense(10, activation='softmax')
])

model_2.compile(loss = "sparse_categorical_crossentropy", optimizer="adam", metrics=["accuracy"])
model_2.fit(training_images, training_labels, batch_size = 64, epochs = 10)
```

Epoch 1/10 [=====] - 4s 4ms/step - loss: 0.5297 - accuracy: 0.8115
Epoch 2/10 [=====] - 4s 4ms/step - loss: 0.4013 - accuracy: 0.8555
Epoch 3/10 [=====] - 4s 4ms/step - loss: 0.3626 - accuracy: 0.8690
Epoch 4/10 [=====] - 4s 4ms/step - loss: 0.3358 - accuracy: 0.8785
Epoch 5/10 [=====] - 4s 4ms/step - loss: 0.3163 - accuracy: 0.8838
Epoch 6/10 [=====] - 4s 4ms/step - loss: 0.2978 - accuracy: 0.8910
Epoch 7/10 [=====] - 4s 4ms/step - loss: 0.2830 - accuracy: 0.8954
Epoch 8/10 [=====] - 4s 4ms/step - loss: 0.2620 - accuracy: 0.8993
Epoch 9/10 [=====] - 4s 4ms/step - loss: 0.2558 - accuracy: 0.9043
Epoch 10/10 [=====] - 4s 4ms/step - loss: 0.2462 - accuracy: 0.9089
Keras.callbacks.History at 0x1b90d00a60>

In [14]:

```
## Tu código para 1024 neuronas aquí ##
model_3 = keras.Sequential([
    keras.layers.Flatten(input_shape=(28, 28)),
    keras.layers.Dense(1024, activation='sigmoid'),
    keras.layers.Dense(10, activation='softmax')
])

model_3.compile(loss = "sparse_categorical_crossentropy", optimizer="adam", metrics=["accuracy"])
model_3.fit(training_images, training_labels, batch_size = 64, epochs = 10)
```

Epoch 1/10 [=====] - 6s 6ms/step - loss: 0.5192 - accuracy: 0.8133
Epoch 2/10 [=====] - 6s 6ms/step - loss: 0.4008 - accuracy: 0.8554
Epoch 3/10 [=====] - 6s 6ms/step - loss: 0.3619 - accuracy: 0.8681
Epoch 4/10 [=====] - 6s 6ms/step - loss: 0.3351 - accuracy: 0.8771
Epoch 5/10 [=====] - 6s 6ms/step - loss: 0.3171 - accuracy: 0.8852
Epoch 6/10 [=====] - 6s 6ms/step - loss: 0.2939 - accuracy: 0.8910
Epoch 7/10 [=====] - 6s 6ms/step - loss: 0.2780 - accuracy: 0.8971
Epoch 8/10 [=====] - 6s 6ms/step - loss: 0.2620 - accuracy: 0.9022
Epoch 9/10 [=====] - 6s 6ms/step - loss: 0.2491 - accuracy: 0.9063
Epoch 10/10 [=====] - 6s 6ms/step - loss: 0.2373 - accuracy: 0.9114
Keras.callbacks.History at 0x1b90d53a100>

Out [14]:

```
tu respuesta a la pregunta 4.3 aquí: el accuracy con mas neuronas incrementa, aunque la velocidad de ejecución disminuye. Con 1024 neuronas el accuracy sube de 89.9 a 91.14
```

In [15]:

```
## Tu código del clasificador de la pregunta 5 aquí ##
classifications_2 = model.predict(test_images)
print(classifications_2[0])
classifications_3 = model.predict(test_images)
print(classifications_3[0])
```

[4.2243528e-07 6.2569725e-08 3.2545759e-07 2.2208357e-07 6.9335954e-08 1.0819657e-02 5.0021135e-06 3.4473564e-02 3.7391858e-07 9.5470029e-01]
[4.2243528e-07 6.2569725e-08 3.2545759e-07 2.2208357e-07 6.9335954e-08 1.0819657e-02 5.0021135e-06 3.4473564e-02 3.7391858e-07 9.5470029e-01]

Ejercicio 3: ¿por qué es tan importante la capa Flatten?

En este ejercicio vamos a ver que ocurre cuando quitamos la capa flatten, para ello, escribe la red neuronal de la pregunta 1 y no pongas la capa Flatten.

In [17]:

```
## Tu código de la red neuronal sin capa flatten de la pregunta 6 aquí ##
model_4 = keras.Sequential([
    keras.layers.Flatten(input_shape=(28, 28)),
    keras.layers.Dense(1024, activation='sigmoid'),
    keras.layers.Dense(10, activation='softmax')
])

model_4.compile(loss = "sparse_categorical_crossentropy", optimizer="adam", metrics=["accuracy"])
model_4.fit(training_images, training_labels, batch_size = 64, epochs = 10)
```

Epoch 1/10 [=====] - 1s 1ms/step - loss: 0.5297 - accuracy: 0.8115
Epoch 2/10 [=====] - 1s 1ms/step - loss: 0.4013 - accuracy: 0.8555
Epoch 3/10 [=====] - 1s 1ms/step - loss: 0.3626 - accuracy: 0.8690
Epoch 4/10 [=====] - 1s 1ms/step - loss: 0.3358 - accuracy: 0.8785
Epoch 5/10 [=====] - 1s 1ms/step - loss: 0.3163 - accuracy: 0.8838
Epoch 6/10 [=====] - 1s 1ms/step - loss: 0.2978 - accuracy: 0.8910
Epoch 7/10 [=====] - 1s 1ms/step - loss: 0.2830 - accuracy: 0.8954
Epoch 8/10 [=====] - 1s 1ms/step - loss: 0.2620 - accuracy: 0.8993
Epoch 9/10 [=====] - 1s 1ms/step - loss: 0.2558 - accuracy: 0.9043
Epoch 10/10 [=====] - 1s 1ms/step - loss: 0.2462 - accuracy: 0.9089
Keras.callbacks.History at 0x1b90d00a60>

InvalidArgumentError: Graph execution error:
Detected at node 'sparse_categorical_crossentropy/SparseSoftmaxCrossEntropyWithLogits/SparseSoftmaxCrossEntropyWithLogits' defined at (most recent call last):
File "C:\ProgramData\Anaconda3\lib\runpy.py", line 197, in run_module_as_main
return run_code(code, main_globals, None,
File "C:\ProgramData\Anaconda3\lib\runpy.py", line 87, in run_code
exec(code, run_globals)
File "C:\ProgramData\Anaconda3\lib\site-packages\ipykernel_launcher.py", line 16, in <module>
app.launch_new_instance()
app.launch_new_instance()
File "C:\ProgramData\Anaconda3\lib\site-packages\traitlets\config\application.py", line 846, in launch_instance
app.start()
File "C:\ProgramData\Anaconda3\lib\site-packages\ipykernel\kernelapp.py", line 677, in start
self.io_loop.start()
File "C:\ProgramData\Anaconda3\lib\site-packages\tornado\platform\asyncio.py", line 199, in start
self.asyncio_loop.run_forever()
File "C:\ProgramData\Anaconda3\lib\asyncio\base_events.py", line 596, in run_forever
self.run_once()
File "C:\ProgramData\Anaconda3\lib\asyncio\base_events.py", line 1890, in run_once
handle._run()
File "C:\ProgramData\Anaconda3\lib\site-packages\ipykernel\events.py", line 80, in _run
self._context.run(self._callback, *self._args)
File "C:\ProgramData\Anaconda3\lib\site-packages\ipykernel\kernelbase.py", line 457, in dispatch_queue
await self._process_one()
File "C:\ProgramData\Anaconda3\lib\site-packages\ipykernel\kernelbase.py", line 446, in process_one
await dispatch(*args)
File "C:\ProgramData\Anaconda3\lib\site-packages\ipykernel\kernelbase.py", line 353, in dispatch_shell
await result
File "C:\ProgramData\Anaconda3\lib\site-packages\ipykernel\kernelbase.py", line 648, in execute_request
reply_content = await reply_content
File "C:\ProgramData\Anaconda3\lib\site-packages\ipykernel\ipkernel.py", line 353, in do_execute
res = shell.run_cell(code, store_history=store_history, silent=silent)
File "C:\ProgramData\Anaconda3\lib\site-packages\ipykernel\zmqshell.py", line 533, in run_cell
return super(ZMQInteractiveShell, self).run_cell(*args, **kwargs)
File "C:\ProgramData\Anaconda3\lib\site-packages\IPython\core\interactiveshell.py", line 2901, in run_cell
result = self.run_cell_inner(*args, **kwargs)
File "C:\ProgramData\Anaconda3\lib\site-packages\IPython\core\interactiveshell.py", line 2947, in run_cell_inner
return runner.run_cell(*args, **kwargs)
File "C:\ProgramData\Anaconda3\lib\site-packages\IPython\core\async_helpers.py", line 68, in _pseudo_sync_runner
coro.send(None)
File "C:\ProgramData\Anaconda3\lib\site-packages\IPython\core\interactiveshell.py", line 3172, in run_cell_async
has_raised = await self.run_ast_nodes(code_ast.body, cell_name,
File "C:\ProgramData\Anaconda3\lib\site-packages\IPython\core\interactiveshell.py", line 3364, in run_ast_nodes
if (await self.run_cell(code, result=async_res, None)):
File "C:\ProgramData\Anaconda3\lib\site-packages\IPython\core\interactiveshell.py", line 3444, in run_code
exec(code_obj, self.user_global_ns, self.user_ns)
File "C:\Users\ASU\AppData\Local\Temp\ipykernel_7016\895817041.py", line 9, in <module>
model_5.fit(training_images, training_labels, batch_size = 64, epochs = 10)
File "C:\ProgramData\Anaconda3\lib\site-packages\keras\utils\traceback_utils.py", line 64, in error_handler
return fn(*args, **kwargs)
File "C:\ProgramData\Anaconda3\lib\site-packages\keras\engine\training.py", line 1384, in fit
tmp_logg = self.train_function(iterator)
File "C:\ProgramData\Anaconda3\lib\site-packages\keras\engine\training.py", line 1021, in train_function
return step_function(self, iterator)
File "C:\ProgramData\Anaconda3\lib\site-packages\keras\engine\training.py", line 1010, in step_function
outputs = model.distribute_strategy.run(run_step, args=(data,))
File "C:\ProgramData\Anaconda3\lib\site-packages\keras\engine\training.py", line 1000, in run_step
outputs = model.train_step(data)
File "C:\ProgramData\Anaconda3\lib\site-packages\keras\engine\training.py", line 860, in train_step
loss = self.compute_loss(y, y_pred, sample_weight)
File "C:\ProgramData\Anaconda3\lib\site-packages\keras\engine\training.py", line 918, in compute_loss
return self.compiled_loss()
File "C:\ProgramData\Anaconda3\lib\site-packages\keras\engine\compile_utils.py", line 201, in _call__
loss_value = loss_obj(y, y_pred, sample_weight)
File "C:\ProgramData\Anaconda3\lib\site-packages\keras\losses.py", line 141, in _call__
losses = call_fn(y_true, y_pred)
File "C:\ProgramData\Anaconda3\lib\site-packages\keras\losses.py", line 245, in call
return ag_fn(y_true, y_pred, **self._fn_kwargs)
File "C:\ProgramData\Anaconda3\lib\site-packages\keras\losses.py", line 1862, in sparse_categorical_crossentropy
return backend.sparse_categorical_crossentropy(y, x, from_logits=True)
File "C:\ProgramData\Anaconda3\lib\site-packages\keras\backend.py", line 5202, in sparse_categorical_crossentropy
res = tf.nn.sparse_softmax_cross_entropy_with_logits(logits=logits, labels=labels)
Node: 'sparse_categorical_crossentropy/SparseSoftmaxCrossEntropyWithLogits/SparseSoftmaxCrossEntropyWithLogits'
Received a label value of 9 which is outside the valid range of (0, 5). Label values: 9 5 3 4 0 6 1 3 5 4 9 1 3 6 0 2 6 8 5 1 7 5 8 9 9 5 6 3 4 3 6 8 3 7 6 3 5 8 3 4 6 9 2 7 8 7 2 8 1 7 3 0 2 9 9 6 4 6 4
[[(node sparse_categorical_crossentropy/SparseSoftmaxCrossEntropyWithLogits/SparseSoftmaxCrossEntropyWithLogits)]]
[[inference_train_function_1993979]]
Tu respuesta a la pregunta 7.1 aquí: por que es el número de categorías existentes

Tu respuestas a la pregunta 7.2 aquí: el error nos indica que es un error de dimensionalidad, ya que el número esperado es igual al número de categorías existentes

Ejercicio 4: Número de neuronas de la capa de salida

Considera la capa final, la de salida de la red neuronal de la pregunta 1.

In [18]:

```
## Tu código de la red neuronal con 5 neuronas en la capa de salida de la pregunta 7 aquí ##
model_5 = keras.Sequential([
    keras.layers.Flatten(input_shape=(28, 28)),
    keras.layers.Dense(1024, activation='sigmoid'),
    keras.layers.Dense(5, activation='softmax')
])

model_5.compile(loss = "sparse_categorical_crossentropy", optimizer="adam", metrics=["accuracy"])
model_5.fit(training_images, training_labels, batch_size = 64, epochs = 10)
```

Epoch 1/10 [=====] - 1s 1ms/step - loss: 0.5297 - accuracy: 0.8115
Epoch 2/10 [=====] - 1s 1ms/step - loss: 0.4013 - accuracy: 0.8555
Epoch 3/10 [=====] - 1s 1ms/step - loss: 0.3626 - accuracy: 0.8690
Epoch 4/10 [=====] - 1s 1ms/step - loss: 0.3358 - accuracy: 0.8785
Epoch 5/10 [=====] - 1s 1ms/step - loss: 0.3163 - accuracy: 0.8838
Epoch 6/10 [=====] - 1s 1ms/step - loss: 0.2978 - accuracy: 0.8910
Epoch 7/10 [=====] - 1s 1ms/step - loss: 0.2830 - accuracy: 0.8954
Epoch 8/10 [=====] - 1s 1ms/step - loss: 0.2620 - accuracy: 0.8993
Epoch 9/10 [=====] - 1s 1ms/step - loss: 0.2558 - accuracy: 0.9043
Epoch 10/10 [=====] - 1s 1ms/step - loss: 0.2462 - accuracy: 0.9089
Keras.callbacks.History at 0x1b90e356490>

Out [18]:

```
tu respuesta a la pregunta 8.3 aquí: se considera overfitting por que llega un momento en que el resultado de la evaluación entre loss y accuracy no cambia en absoluto, por definición la red neuronal memoriza pero no aprende. Una buena forma de arreglar esto sería BatchNormalización o vgg16, incluso ambos.
```

Ejercicio 5: Early stop

En el ejercicio anterior, cuando entrenabas con epoch estas, tenías un problema en el que tu pérdida podía cambiar. Puede que te haya llevado un poco de tiempo esperar a que el entrenamiento lo hiciera, y puede que hayas pensado "no estaba bien si pudiera parar el entrenamiento cuando alcance un valor deseado", es decir, la precisión del 85% podría ser suficiente para ti, si alcanzas eso después de 3 epoch, ¿por qué sentarte a esperar a que termine muchas más épocas? Como cualquier otro programa existen formas de parar la ejecución.

In []:

```
## Ejemplo de código
class Callback(tf.keras.callbacks.Callback):
    def on_epoch_end(self, epoch, logs={}):
        if logs.get('accuracy') > 0.85:
            print("\nAlcanzado el 85% de precisión, se cancela el entrenamiento!")
            self.model.stop_training = True
```


Pregunta 9 (2 puntos): Completa el siguiente código con una clase callback que una vez alcanzado el 40% de pérdida detenga el entrenamiento.

```
In [22]: import tensorflow as tf
        print(tf.__version__)

        ## Tu código de la función callback para parar el entrenamiento de la red neuronal al 40% de
        ## loss aquí: ##

        class myCallback (tf.keras.callbacks.Callback):
            def on_epoch_end (self,epoch,logs={}):
                if(log.get("loss") > 0.4):
                    print("perdida del 40%")
                    self.model.stop_training = True

        callbacks = myCallback()
        mnist = tf.keras.datasets.fashion_mnist
        (training_images, training_labels) , (test_images, test_labels) = mnist.load_data()

        training_images = training_images/255.0
        test_images = test_images/255.0

        model = tf.keras.models.Sequential([tf.keras.layers.Flatten(),
                                            tf.keras.layers.Dense(512, activation=tf.nn.relu),
                                            tf.keras.layers.Dense(10, activation=tf.nn.softmax)])

        model.compile(optimizer = 'adam',
                      loss = 'sparse_categorical_crossentropy',
                      metrics=['accuracy'])

        model.fit(training_images, training_labels, epochs=50, callbacks=[callbacks])

2.8.0
Epoch 1/50
1875/1875 [=====] - 8s 4ms/step - loss: 0.4760 - accuracy: 0.8292
Epoch 2/50
1875/1875 [=====] - 7s 4ms/step - loss: 0.3584 - accuracy: 0.8686
Epoch 3/50
1875/1875 [=====] - 7s 4ms/step - loss: 0.3224 - accuracy: 0.8811
Epoch 4/50
1875/1875 [=====] - 7s 4ms/step - loss: 0.2991 - accuracy: 0.8899
Epoch 5/50
1875/1875 [=====] - 7s 4ms/step - loss: 0.2784 - accuracy: 0.8966
Epoch 6/50
1875/1875 [=====] - 7s 4ms/step - loss: 0.2651 - accuracy: 0.9013
Epoch 7/50
1875/1875 [=====] - 7s 4ms/step - loss: 0.2524 - accuracy: 0.9056
Epoch 8/50
1875/1875 [=====] - 7s 4ms/step - loss: 0.2415 - accuracy: 0.9100
Epoch 9/50
1875/1875 [=====] - 7s 4ms/step - loss: 0.2301 - accuracy: 0.9149
Epoch 10/50
1875/1875 [=====] - 7s 4ms/step - loss: 0.2210 - accuracy: 0.9174
Epoch 11/50
1875/1875 [=====] - 7s 4ms/step - loss: 0.2127 - accuracy: 0.9197
Epoch 12/50
1875/1875 [=====] - 7s 4ms/step - loss: 0.2028 - accuracy: 0.9230
Epoch 13/50
1875/1875 [=====] - 7s 4ms/step - loss: 0.1970 - accuracy: 0.9251
Epoch 14/50
1875/1875 [=====] - 7s 4ms/step - loss: 0.1903 - accuracy: 0.9281
Epoch 15/50
1875/1875 [=====] - 7s 4ms/step - loss: 0.1848 - accuracy: 0.9303
Epoch 16/50
1875/1875 [=====] - 7s 4ms/step - loss: 0.1799 - accuracy: 0.9319
Epoch 17/50
1875/1875 [=====] - 7s 4ms/step - loss: 0.1734 - accuracy: 0.9336
Epoch 18/50
1875/1875 [=====] - 7s 4ms/step - loss: 0.1681 - accuracy: 0.9376
Epoch 19/50
1875/1875 [=====] - 7s 4ms/step - loss: 0.1619 - accuracy: 0.9388
Epoch 20/50
1875/1875 [=====] - 7s 4ms/step - loss: 0.1587 - accuracy: 0.9395
Epoch 21/50
1875/1875 [=====] - 7s 4ms/step - loss: 0.1537 - accuracy: 0.9414
Epoch 22/50
1875/1875 [=====] - 7s 4ms/step - loss: 0.1475 - accuracy: 0.9445
Epoch 23/50
1875/1875 [=====] - 7s 4ms/step - loss: 0.1432 - accuracy: 0.9468
Epoch 24/50
1875/1875 [=====] - 7s 4ms/step - loss: 0.1392 - accuracy: 0.9478
Epoch 25/50
1875/1875 [=====] - 7s 4ms/step - loss: 0.1394 - accuracy: 0.9464
Epoch 26/50
1875/1875 [=====] - 7s 4ms/step - loss: 0.1329 - accuracy: 0.9494
Epoch 27/50
1875/1875 [=====] - 7s 4ms/step - loss: 0.1285 - accuracy: 0.9515
Epoch 28/50
1875/1875 [=====] - 7s 4ms/step - loss: 0.1271 - accuracy: 0.9521
Epoch 29/50
1875/1875 [=====] - 7s 4ms/step - loss: 0.1255 - accuracy: 0.9522
Epoch 30/50
1875/1875 [=====] - 7s 4ms/step - loss: 0.1192 - accuracy: 0.9546
Epoch 31/50
1875/1875 [=====] - 7s 4ms/step - loss: 0.1162 - accuracy: 0.9563
Epoch 32/50
1875/1875 [=====] - 7s 4ms/step - loss: 0.1148 - accuracy: 0.9574
Epoch 33/50
1875/1875 [=====] - 7s 4ms/step - loss: 0.1126 - accuracy: 0.9578
Epoch 34/50
1875/1875 [=====] - 7s 4ms/step - loss: 0.1080 - accuracy: 0.9589
Epoch 35/50
1875/1875 [=====] - 7s 4ms/step - loss: 0.1047 - accuracy: 0.9602
Epoch 36/50
1875/1875 [=====] - 7s 4ms/step - loss: 0.1042 - accuracy: 0.9615
Epoch 37/50
1875/1875 [=====] - 7s 4ms/step - loss: 0.1009 - accuracy: 0.9612
Epoch 38/50
1875/1875 [=====] - 7s 4ms/step - loss: 0.0990 - accuracy: 0.9622
Epoch 39/50
1875/1875 [=====] - 7s 4ms/step - loss: 0.0995 - accuracy: 0.9621
Epoch 40/50
1875/1875 [=====] - 7s 4ms/step - loss: 0.0941 - accuracy: 0.9641
Epoch 41/50
1875/1875 [=====] - 7s 4ms/step - loss: 0.0957 - accuracy: 0.9641
Epoch 42/50
1875/1875 [=====] - 7s 4ms/step - loss: 0.0911 - accuracy: 0.9657
Epoch 43/50
1875/1875 [=====] - 7s 4ms/step - loss: 0.0918 - accuracy: 0.9654
Epoch 44/50
1875/1875 [=====] - 7s 4ms/step - loss: 0.0897 - accuracy: 0.9657
Epoch 45/50
1875/1875 [=====] - 7s 4ms/step - loss: 0.0866 - accuracy: 0.9671
Epoch 46/50
1875/1875 [=====] - 7s 4ms/step - loss: 0.0840 - accuracy: 0.9675
Epoch 47/50
1875/1875 [=====] - 7s 4ms/step - loss: 0.0858 - accuracy: 0.9684
Epoch 48/50
1875/1875 [=====] - 7s 4ms/step - loss: 0.0822 - accuracy: 0.9701
Epoch 49/50
1875/1875 [=====] - 7s 4ms/step - loss: 0.0792 - accuracy: 0.9701
Epoch 50/50
1875/1875 [=====] - 7s 4ms/step - loss: 0.0818 - accuracy: 0.9685
Keras.callbacks.History at 0x1b90b628c10>
```

Out[22]: